

Analisis Kinerja Algoritma Naive Bayes, SVM dan Random Forest dalam Deteksi Hoaks Berita (Studi Kasus Bahasa Indonesia)

Proposal Tugas Akhir

Oleh

Muhammad Nurul Hakim
18222097



PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Desember 2025

LEMBAR PENGESAHAN

Analisis Kinerja Algoritma Naive Bayes, SVM dan Random Forest dalam Deteksi Hoaks Berita (Studi Kasus Bahasa Indonesia)

Proposal Tugas Akhir

Oleh

Muhammad Nurul Hakim
18222097

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 5 Desember 2025

Pembimbing

Dr. Riza Satria Perdana, S.T, M.T.
NIP.197006091995121002

DAFTAR ISI

DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR KODE	vi
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	2
I.3 Tujuan	3
I.4 Batasan Masalah	4
I.5 Metodologi	4
II STUDI LITERATUR	6
II.1 Hoaks dan Tantangan Kualitas Informasi di Era Digital	6
II.2 Pendekatan Deteksi Hoaks (ML Klasik, DL, dan LLM)	8
II.3 <i>Preprocessing</i> Teks Bahasa Indonesia dan Representasi TF-IDF	10
II.3.1 <i>Preprocessing</i> Teks Bahasa Indonesia	10
II.3.2 Representasi Fitur TF-IDF	12
II.3.3 Justifikasi Penggunaan Representasi TF-IDF	13
II.3.4 Representasi Fitur Sumber dengan One-Hot <i>encoding</i>	14
II.4 Algoritma Naïve Bayes, SVM, dan Random Forest untuk Klasifikasi Teks	16
II.4.1 Naïve Bayes	16
II.4.2 Support Vector Machine (SVM)	17
II.4.3 Random Forest	19
II.5 Metrik Evaluasi Kinerja Model	21
II.5.1 Confusion Matrix dan Komponen Dasarnya	22
II.5.2 Metrik Kinerja dari Confusion Matrix	22
II.6 Penelitian Terkait	24
II.6.1 <i>Hoax News Identification Using Machine Learning Model from Onli- ne Media in Bahasa Indonesia</i> (Pratiwi dan Nugraha (2022))	24
II.6.2 <i>Evaluation of TF-IDF Feature Extraction in Indonesian Hoax News Classification</i> (Prasetyo dkk. (2019))	24
II.6.3 <i>Hoax Detection System on Indonesian News Sites Based on Text Clas- sification Using SVM and SGD</i> (Prasetijo dkk. (2017))	25

II.6.4	Support Vector Machine-Based Hoax Detection on Indonesian Online News (Sihombing (2020))	25
II.6.5	Analysis and Detection of Hoax Contents in Indonesian News (Putri dkk. (2019))	25
II.6.6	Indonesian Fake News Detection Using Machine Learning Techniques (Triyono dkk. (2023))	26
II.6.7	Comparative Analysis of Fake News Detection Using Machine Learning Models (Safira dan Nurlayli (2023))	26
II.6.8	Sintesis dan Research Gap	26
III ANALISIS MASALAH		28
III.1	Analisis Kondisi Saat Ini	28
III.2	Analisis Kebutuhan dalam Implementasi <i>pipeline</i> untuk Deteksi Hoaks .	28
III.3	Analisis Pemilihan Pendekatan Deteksi Hoaks	31
III.3.1	Alternatif Pendekatan Umum yang Dapat Digunakan	32
III.3.2	Pemilihan Pendekatan Deteksi Hoaks	32
IV DESAIN KONSEP SOLUSI		34
IV.1	Gambaran Sistem/Kondisi Saat Ini (<i>As-Is</i>)	34
IV.2	Desain Konsep Solusi yang Diajukan	35
IV.2.1	Konsep Model Pipeline yang Diusulkan(<i>To-Be</i>)	35
IV.2.2	Kondisi <i>To-Be</i>	39
IV.3	Perbandingan Kondisi As-Is dan Konsep Solusi (<i>To-Be</i>)	40
V RENCANA SELANJUTNYA		42
V.1	Rencana Implementasi	42
V.1.1	Langkah Implementasi	42
V.1.2	Alat, Lingkungan, dan Konfigurasi	44
V.2	Desain Pengujian dan Evaluasi	45
V.3	Analisis Risiko dan Mitigasi	45

DAFTAR GAMBAR

I.1	Mdoel Development Stages	4
II.1	<i>Preprocessing steps</i>	10
IV.1	Kondisi <i>As-Is</i> Alur Deteksi Hoaks di Indonesia	34
IV.2	Kondisi <i>To-Be</i> Alur Deteksi Hoaks dengan <i>Pipeline</i> yang Diusulkan	36
IV.3	Kondisi <i>To-Be</i> Alur Deteksi Hoaks di Indonesia	39

DAFTAR TABEL

II.1	Confusion matrix untuk klasifikasi biner deteksi hoaks	22
III.1	Permasalahan deteksi hoaks berita berbahasa Indonesia	29
III.2	Kebutuhan Fungsional dalam Implementasi <i>pipeline</i>	30
III.3	Kebutuhan Non-Fungsional dalam Implementasi <i>pipeline</i>	31
III.4	Perbandingan pendekatan untuk deteksi hoaks	32
IV.1	Perbandingan kondisi saat ini dan konsep solusi yang diusulkan . .	40
V.1	Rencana Implementasi	42
V.2	Spesifikasi Alat, Bahan, dan Konfigurasi	44
V.3	Tahapan Pengujian dan Evaluasi <i>pipeline</i> Deteksi Hoaks	46
V.4	Identifikasi risiko dan strategi mitigasi	46

DAFTAR KODE

BAB I

PENDAHULUAN

I.1 Latar Belakang

Perkembangan teknologi digital saat ini telah mengubah cara masyarakat mencari, menerima, dan menyebarkan informasi yang ada. Setiap hari informasi beredar sangat cepat, karena akses yang semakin luas dan cepat inilah informasi beredar dengan kecepatan yang tidak ter-*filter*, Ini menghadirkan masalah serius berupa meningkatnya penyebaran misinformasi dan disinformasi. Alghamdi, Luo, dan Lin (2024) menunjukkan bahwa hoaks dapat menyebar lebih cepat dibandingkan informasi akurat karena dipengaruhi oleh perilaku pengguna, bias psikologis, hingga pola interaksi dalam ruang digital yang tertutup. Faktor-faktor tersebut memperkuat posisi hoaks sebagai ancaman nyata terhadap kualitas pemahaman publik dan proses pengambilan keputusan di masyarakat.

Penelitian internasional oleh Emil dan Remus (2025) juga menggambarkan bahwa hoaks masa kini memiliki bentuk yang semakin kompleks, mulai dari permainan bahasa hingga penyalahgunaan konteks berita. Volume penyebarannya yang sangat besar membuat verifikasi manual tidak lagi memadai sehingga dibutuhkan dukungan teknologi yang mampu melakukan deteksi otomatis secara cepat dan konsisten. Dalam konteks ini, *machine learning* menjadi salah satu pendekatan yang paling banyak digunakan karena mampu mengenali pola linguistik tertentu yang sering muncul pada konten hoaks.

Kondisi tersebut semakin relevan ketika melihat situasi di Indonesia, di mana konsumsi informasi melalui media daring dan media sosial terus meningkat. Penyebaran hoaks dalam bahasa Indonesia telah dibuktikan oleh berbagai penelitian, salah satunya oleh Pratiwi dan Nugraha (2022) yang mengidentifikasi masih banyaknya konten menyesatkan di media daring lokal. Penelitian mereka menggunakan algoritma Naïve Bayes pada *dataset* berita Indonesia dan mendapatkan akurasi sebesar

71%, yang menunjukkan bahwa pendekatan berbasis *machine learning* cukup efektif untuk mendukung deteksi awal hoaks pada konten berbahasa Indonesia (Pratiwi dan Nugraha 2022). Temuan ini memperlihatkan bahwa kebutuhan terhadap metode otomatis bukan hanya relevan secara global, tetapi juga sangat mendesak dalam konteks lokal.

Penelitian lainnya oleh Triyono dkk. (2023) menunjukkan bahwa berbagai algoritma *machine learning* telah diuji dalam mendeteksi hoaks Indonesia dan memberikan hasil yang beragam. Support Vector Machine (SVM) tercatat memiliki performa paling tinggi dengan akurasi 83,55%, diikuti algoritma lain seperti Random Forest dan Logistic Regression yang menunjukkan kinerja cukup kompetitif meskipun tidak selalu konsisten dalam berbagai skenario data (Triyono dkk. 2023). Meskipun demikian, sebagian besar penelitian tersebut masih fokus pada pendekatan berbasis isi teks. Pendekatan ini penting karena konten merupakan elemen utama dari sebuah berita, tetapi beragamnya gaya penulisan, struktur bahasa, serta variasi kosakata dalam bahasa Indonesia membuat evaluasi menyeluruh terhadap beberapa algoritma sekaligus menjadi sangat diperlukan.

Berdasarkan perkembangan tersebut, Tugas Akhir ini diarahkan untuk menganalisis kinerja tiga algoritma *machine learning* yang umum digunakan dalam deteksi hoaks, yaitu Naïve Bayes, Support Vector Machine, dan Random Forest. Ketiga algoritma ini dipilih karena sering digunakan dalam penelitian sebelumnya dan memiliki karakteristik berbeda dalam memproses teks sehingga memungkinkan dilakukan perbandingan yang lebih komprehensif. Dengan menguji ketiganya pada *dataset* berita berbahasa Indonesia, penelitian ini diharapkan dapat memberikan pemahaman yang lebih jelas mengenai efektivitas, kelebihan, dan keterbatasan masing-masing model ketika diterapkan pada konteks lokal.

Hasil Tugas Akhir diharapkan dapat mendukung pengembangan sistem deteksi hoaks yang lebih akurat dan relevan untuk kebutuhan nasional, sekaligus memberikan kontribusi bagi upaya menjaga kualitas ekosistem informasi digital yang sehat dan dapat dipercaya.

I.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka rumusan masalah dalam tugas akhir ini adalah sebagai berikut:

1. Bagaimana merancang proses deteksi hoaks berita berbahasa Indonesia menggunakan pendekatan content-based, yang melibatkan tahapan *preprocessing*,

feature extraction, dan *classification* dengan algoritma *machine learning* klasik seperti Naïve Bayes, Support Vector Machine (SVM), dan Random Forest?

2. Bagaimana kinerja komparatif ketiga algoritma tersebut dalam mengklasifikasikan berita hoaks dan non-hoaks berdasarkan metrik kuantitatif seperti *accuracy*, *precision*, *recall*, dan F1-score?
3. Bagaimana pengaruh penambahan fitur sumber berita (*source-based features*)—seperti domain atau tipe sumber—terhadap performa model klasifikasi dibandingkan model berbasis *content-only*?
4. Bagaimana merancang model deteksi yang *replicable* dan efisien, sehingga dapat menjadi *benchmark* awal untuk penelitian lanjutan di bidang deteksi hoaks berbahasa Indonesia?

Permasalahan di atas penting untuk dikaji karena belum tersedia studi komparatif yang sistematis mengenai performa algoritma *machine learning* klasik dalam mendeteksi hoaks dalam bahasa Indonesia, khususnya dengan integrasi fitur berbasis konten dan sumber. Hasil dari penelitian ini diharapkan dapat memberikan dasar empiris bagi pengembangan sistem deteksi hoaks yang akurat dan adaptif dalam ekosistem digital nasional.

I.3 Tujuan

Tujuan dari tugas akhir ini adalah untuk memberikan solusi terhadap permasalahan yang telah dirumuskan sebelumnya. Secara khusus, tujuan Tugas Akhir ini adalah sebagai berikut:

1. Merancang dan mengimplementasikan *pipeline* deteksi hoaks berita berbahasa Indonesia menggunakan pendekatan *content-based* melalui tahapan utama *preprocessing*, *feature extraction* (TF-IDF), dan *classification* dengan algoritma *machine learning* klasik: Naïve Bayes, SVM, dan Random Forest.
2. Menganalisis dan membandingkan kinerja ketiga algoritma tersebut dalam mengklasifikasikan berita hoaks dan non-hoaks berdasarkan metrik kuantitatif, yaitu *accuracy*, *precision*, *recall*, dan F1-score, untuk menentukan model dengan performa terbaik.
3. Mengeksplorasi pengaruh penambahan fitur sumber berita sederhana (*source-based features*), seperti domain situs atau jenis sumber berita, terhadap hasil klasifikasi, dan membandingkannya dengan model berbasis *content-only*.
4. Menyusun dokumentasi teknis dan hasil evaluasi model yang *replicable*, mencakup konfigurasi algoritma, kombinasi fitur, serta parameter utama yang da-

pat dijadikan *benchmark* untuk penelitian dan implementasi sistem deteksi hoaks di masa depan.


I.4 Batasan Masalah

Batasan masalah dalam tugas akhir ini adalah sebagai berikut:

1. Tugas akhir berfokus pada deteksi hoaks berita berbahasa Indonesia yang bersumber dari *platform* situs berita daring.
2. Pendekatan yang digunakan adalah *content-based*, dengan fokus pada analisis teks berita menggunakan tahapan utama *preprocessing*, *feature extraction* (TF-IDF), dan *classification* menggunakan algoritma *machine learning* klasik, yaitu ada Naïve Bayes, SVM, dan Random Forest.
3. *Dataset* yang digunakan adalah kumpulan berita hoaks dan non-hoaks yang telah tersedia secara publik, dengan pembagian data menjadi set pelatihan dan pengujian.
4. Evaluasi kinerja model dilakukan menggunakan metrik kuantitatif: *accuracy*, *precision*, *recall*, dan *F1-score*.
5. Tugas Akhir ini tidak mencakup pendekatan berbasis jaringan sosial atau metode *deep learning* seperti Graph Neural Networks (GNN) atau Transformer.
6. Penambahan fitur sumber berita (*source-based features*) yang dieksplorasi terbatas pada atribut sederhana seperti domain situs atau jenis sumber berita.

I.5 Metodologi

Secara umum, Tugas Akhir ini menggunakan pendekatan *machine learning* untuk menganalisis dan membandingkan performa tiga algoritma dalam mendeteksi hoaks berita berbahasa Indonesia. Agar penelitian berjalan secara terstruktur, alur kerja disusun mengikuti tahapan dasar yang lazim digunakan dalam studi klasifikasi teks pada penelitian sebelumnya. Tahapannya kurang lebih akan terdiri dari 5 tahapan utama seperti yang ditunjukkan pada Gambar I.1. Secara garis besar, metode Tugas Akhir ini meliputi langkah-langkah sebagai berikut.



Gambar I.1 Model Development Stages

1. Pengumpulan *Dataset*

Tugas Akhir dimulai dengan menghimpun data berita hoaks dan non-hoaks dari sumber yang telah diverifikasi. Pendekatan ini mengikuti pola penelitian Pratiwi dan Nugraha (2022) yang memanfaatkan data dari media daring dalam bahasa Indonesia untuk membangun model klasifikasi hoaks. Tahap pengumpulan data difokuskan pada memperoleh contoh teks yang mewakili penggunaan bahasa dalam konteks berita hoaks di Indonesia sehingga model memiliki dasar pembelajaran yang sesuai dengan kasus yang diteliti.

2. *Preprocessing* Teks

Setelah *dataset* terkumpul, teks diproses untuk menyeragamkan struktur dan menghilangkan elemen yang tidak relevan. Proses ini mencakup pembersihan dasar seperti normalisasi huruf, pemisahan kata, penghilangan kata umum, dan pengubahan kata menjadi bentuk dasarnya. Pendekatan yang sama digunakan dalam penelitian Sihombing (2020), yang menekankan peran *preprocessing* sebagai fondasi penting sebelum membangun model deteksi hoaks.

3. Ekstraksi Fitur dengan TF-IDF

Teks yang telah dibersihkan kemudian diubah menjadi representasi numerik menggunakan TF-IDF. Teknik ini banyak digunakan pada klasifikasi teks, termasuk klasifikasi hoaks bahasa Indonesia. Prasetyo dkk. (2019) menunjukkan bahwa TF-IDF merupakan metode yang stabil dan efektif untuk mengekstraksi ciri tekstual pada berita hoaks.

4. Pemodelan dengan Algoritma *Machine Learning*

Model dibangun menggunakan tiga algoritma, yaitu Naïve Bayes, Support Vector Machine, dan Random Forest. Ketiga metode ini dipilih karena sering digunakan pada penelitian deteksi hoaks Indonesia dan menunjukkan performa yang kompetitif pada berbagai studi, termasuk Triyono dkk. (2023).

5. Evaluasi Kinerja Model

Tahap akhir adalah mengukur performa model menggunakan metrik evaluasi klasifikasi untuk melihat kemampuan model dalam membedakan berita hoaks dan non-hoaks. Hasil evaluasi ini memberikan dasar objektif untuk menentukan model yang paling sesuai serta melihat potensi penerapan pendekatan berbasis konten dalam deteksi hoaks bahasa Indonesia.

BAB II

STUDI LITERATUR

II.1 Hoaks dan Tantangan Kualitas Informasi di Era Digital

Perkembangan ekosistem digital telah mempermudah produksi dan distribusi informasi dalam skala yang jauh lebih besar dibandingkan sebelumnya. Kemudahan ini membawa manfaat, tetapi juga membuka ruang yang luas bagi munculnya hoaks. Emil dan Remus (2025) menjelaskan bahwa *fake news* berkembang sebagai konsekuensi dari arus informasi yang tidak terkendali, lemahnya mekanisme verifikasi, serta perubahan pola konsumsi informasi masyarakat. Dalam lingkungan digital yang lebih mengutamakan kecepatan, banyak pengguna membagikan informasi tanpa melakukan pengecekan terlebih dahulu. Situasi ini memungkinkan konten palsu menyebar ke ribuan pengguna dalam waktu yang sangat singkat.

Hoaks tidak hanya berbentuk klaim palsu secara langsung. Emil dan Remus (2025) menunjukkan bahwa fenomena ini mencakup spektrum yang lebih luas, mulai dari misinformasi—informasi salah yang disebarkan tanpa niat menipu—hingga disinformasi yang diproduksi secara sengaja untuk memberikan kesan yang menyesatkan. Ada pula mal-informasi, satire, serta manipulasi konten berbasis gambar atau video. Beragamnya bentuk dan gaya penyajian membuat proses identifikasi hoaks semakin rumit karena setiap jenis memiliki pola penyebaran, tujuan, dan dampak yang berbeda.

Tantangan kualitas informasi juga berkaitan erat dengan siapa yang menyebarkannya. Berdasarkan analisis Emil dan Remus (2025), terdapat dua kelompok utama yang berperan dalam memperluas jangkauan hoaks. Kelompok pertama adalah aktor jahat yang secara sengaja memproduksi dan mendistribusikan konten palsu, termasuk bot, akun anonim, atau operasi informasi yang terorganisasi. Kelompok kedua adalah pengguna biasa yang secara tidak sadar ikut menyebarkan hoaks karena rendahnya literasi digital, kecenderungan untuk mempercayai informasi yang sesuai

dengan pandangan pribadi, atau dorongan emosional saat melihat konten tertentu. Kedua kelompok ini mempercepat rantai penyebaran hoaks dan membuat penanganannya semakin kompleks.

Selain faktor perilaku pengguna, dinamika penyebaran konten di media sosial turut memperburuk kondisi kualitas informasi. Alghamdi, Luo, dan Lin (2024) mencatat bahwa yang membuat hoaks sangat mudah viral adalah kecenderungan algoritma untuk mendorong konten yang bersifat sensasional atau emosional. Hal ini dapat meningkatkan polarisasi politik, menyebarkan misinformasi kesehatan, dan memperlemah kepercayaan publik terhadap institusi resmi. Dalam banyak kasus, informasi palsu yang menarik perhatian lebih cepat diterima dan dibagikan oleh pengguna dibandingkan informasi faktual yang biasanya memiliki gaya penyajian yang lebih formal dan kurang menarik secara emosional.

Dilihat dari sisi teknis juga tantangan dalam mendeteksi dan memverifikasi hoaks semakin meningkat. Emil dan Remus (2025) menyoroti bahwa volume data yang sangat besar, keberagaman *platform*, serta hadirnya konten multimodal seperti gambar editan, video manipulatif, dan *deepfake* membuat proses verifikasi manual tidak lagi memadai. Sementara itu, Alghamdi, Luo, dan Lin (2024) menekankan bahwa sistem verifikasi manusia tidak mampu mengimbangi kecepatan penyebaran informasi di media sosial, sehingga banyak konten penting sudah terlanjur viral sebelum sempat diverifikasi oleh lembaga pemeriksa fakta. Ketidakteraturan struktur data, minimnya anotasi, dan variasi konteks membuat verifikasi otomatis pun menghadapi tantangan tersendiri.

Maka dari itu, ini menunjukkan bahwa sebenarnya tantangan kualitas informasi di era digital saat ini tidak hanya disebabkan oleh karakteristik konten yang semakin kompleks, tetapi juga dari perilaku pengguna, mekanisme algoritma *platform*, dan keterbatasan teknologi verifikasi. Tantangan ini menuntut pendekatan multidisipliner yang melibatkan pemahaman mengenai faktor-faktor yang ada, mulai dari faktor sosial, teknis, perilaku, serta peran *platform* dalam mengatur arus informasi. Pemahaman ini yang menjadi dasar penting serta alasan bagi penelitian teknis seperti tugas akhir ini, yang berupaya menganalisis dan mengevaluasi model deteksi hoaks berbasis *machine learning* untuk mendukung kualitas informasi yang lebih aman dan terpercaya.

II.2 Pendekatan Deteksi Hoaks (ML Klasik, DL, dan LLM)

Penelitian mengenai deteksi hoaks telah berkembang melalui berbagai pendekatan yang memiliki fokus analisis berbeda. Secara umum, pendekatan tersebut dapat dipetakan menjadi tiga kategori utama berdasarkan tinjauan Alghamdi, Luo, dan Lin (2024), yaitu berbasis konten, berbasis konteks atau pola penyebaran, dan pendekatan hibrida. Ketiganya berkembang sebagai respons terhadap kebutuhan untuk memahami tidak hanya bagaimana sebuah berita ditulis, tetapi juga bagaimana ia disebarkan serta siapa yang memproduksinya. Kerangka ini menjadi dasar untuk memahami posisi pendekatan yang digunakan dalam penelitian ini.

Pendekatan berbasis konten merupakan metode yang menganalisis karakteristik linguistik dari teks berita. Alghamdi, Luo, dan Lin (2024) menjelaskan bahwa berita hoaks sering kali menggunakan bahasa yang lebih emosional, subjektif, repetitif, dan memiliki struktur kalimat yang cenderung sederhana. Fitur seperti frekuensi kata, kosakata provokatif, tanda baca berlebihan, hingga pola kapitalisasi tertentu dapat menjadi indikator penting bagi model klasifikasi. Pendekatan ini banyak dipakai karena tidak membutuhkan informasi tambahan seperti pola interaksi pengguna dalam jaringan sosial. Selain itu, pendekatan ini efektif untuk deteksi dini, terutama ketika hanya teks yang tersedia. Penelitian ini juga menggunakan metode berbasis konten karena *dataset* berbahasa Indonesia yang digunakan sebagian besar hanya memuat teks berita.

Selain konten, beberapa penelitian mengusulkan pendekatan berbasis konteks atau penyebaran dengan memanfaatkan pola interaksi pengguna, struktur penyebaran informasi, dan dinamika percakapan di media sosial. Contohnya meliputi analisis *engagement* seperti retweet, komentar, atau jaringan percakapan yang dibentuk oleh para pengguna. Pendekatan ini memungkinkan model mendeteksi hoaks berdasarkan pola penyebaran yang tidak biasa atau adanya kemungkinan operasi yang terkoordinasi. Pada banyak studi, pendekatan ini dikembangkan melalui Graph Neural Networks (GNN) yang memodelkan interaksi antar pengguna dan pola distribusi konten. Namun pendekatan tersebut hanya dapat diterapkan apabila tersedia data penyebaran yang lengkap, sesuatu yang tidak relevan untuk *dataset* berita yang digunakan dalam penelitian ini.

Pendekatan ketiga adalah pendekatan hibrida yang menggabungkan analisis konten, informasi konteks, dan metadata sumber untuk menghasilkan prediksi yang lebih komprehensif. Emil dan Remus (2025) menunjukkan bahwa perkembangan terbaru dalam deteksi hoaks semakin mengarah pada penggunaan metadata seperti domain

situs, kredibilitas media, waktu publikasi, dan informasi tambahan lainnya. Pendekatan ini memberikan gambaran yang lebih utuh mengenai kredibilitas suatu berita, meskipun kompleksitasnya lebih tinggi dibandingkan metode berbasis konten saja. Penelitian ini memanfaatkan versi ringan dari pendekatan hibrida dengan menambahkan fitur sumber sederhana seperti domain atau jenis media, sembari mempertahankan fokus utama pada analisis konten.

Seiring dengan beragamnya pendekatan tersebut, metode komputasi untuk deteksi hoaks juga mengalami perkembangan signifikan. Teknik pertama yang banyak digunakan adalah *machine learning* klasik seperti Naïve Bayes, Support Vector Machine, dan Random Forest. Alghamdi, Lin, dan Luo (2022) menegaskan bahwa ketiga algoritma ini memiliki sejumlah keunggulan seperti kebutuhan komputasi yang rendah, interpretabilitas yang baik, serta performa yang stabil pada *dataset* berukuran sedang. SVM dikenal efektif untuk data berdimensi tinggi, Naïve Bayes sederhana tetapi kuat untuk teks pendek, sedangkan Random Forest unggul dalam stabilitas melalui pendekatan *ensemble*. Meskipun demikian, metode ini membutuhkan rekayasa fitur manual dan sering kali tidak dapat menangkap hubungan semantik yang lebih kompleks dalam teks panjang.

Perkembangan berikutnya adalah penggunaan *deep learning*, termasuk CNN, RNN, LSTM, serta model transformer seperti BERT. Model-model ini mampu mengenali pola konteks jangka panjang dalam teks dan menangkap makna bahasa secara lebih mendalam. Emil dan Remus (2025) menyoroti bahwa model berbasis transformer menjadi sangat dominan karena mampu mempelajari hubungan antar kata dalam satu kalimat secara lebih efektif dibandingkan metode tradisional. Studi Pekandi dkk. (2025) menunjukkan bahwa IndoBERT—model transformer yang dilatih khusus pada bahasa Indonesia—mampu mencapai akurasi hingga 92 persen untuk deteksi hoaks, melampaui model CNN-LSTM dan *ensemble machine learning* klasik. Meskipun demikian, model-model *deep learning* membutuhkan *dataset* besar, sumber daya komputasi tinggi, serta proses pelatihan yang lebih kompleks.

Perkembangan paling mutakhir dalam deteksi hoaks adalah penggunaan *large language models* (LLM). Emil dan Remus (2025) menjelaskan bahwa LLM seperti GPT, LLaMA, atau Gemini memiliki kemampuan menganalisis teks dengan pemahaman konteks yang lebih luas, menghasilkan data tambahan, merangkum informasi, atau melakukan penalaran berbasis pengetahuan eksternal. Meskipun memiliki potensi besar, penggunaan LLM juga menghadapi tantangan seperti biaya komputasi yang tinggi, risiko halusinasi, serta kebutuhan evaluasi yang ketat untuk memas-

tikan keandalan prediksi.


Dengan memahami seluruh peta pendekatan tersebut, Tugas Akhir ini menempatkan dirinya sebagai studi berbasis konten yang menggunakan algoritma *machine learning* klasik dengan eksplorasi terbatas pada metadata sumber. Pemilihan pendekatan ini didasarkan pada karakteristik *dataset*, kebutuhan efisiensi, serta relevansinya sebagai *baseline* yang kokoh untuk penelitian lanjutan. Selain itu, batasan ruang lingkup tugas akhir membuat pendekatan berbasis ML klasik menjadi pilihan yang realistis dan sesuai dengan tujuan Tugas Akhir, sementara model *deep learning* atau transformer ditempatkan sebagai peluang pengembangan pada tahap berikutnya.

II.3 *Preprocessing* Teks Bahasa Indonesia dan Representasi TF-IDF

TF-IDF (Term Frequency-Inverse Document Frequency) merupakan metode representasi teks yang paling umum digunakan dalam klasifikasi dokumen. Metode ini menghitung bobot suatu kata dalam sebuah dokumen berdasarkan seberapa sering kata tersebut muncul di dokumen tertentu, dan seberapa jarang kata tersebut muncul di seluruh korpus. TF-IDF efektif dalam menghilangkan kata-kata umum (seperti “yang”, “adalah”, “itu”) dan menonjolkan kata-kata penting yang menjadi penanda topik sebuah berita.

Beberapa penelitian telah membuktikan bahwa TF-IDF sangat efektif dalam meningkatkan akurasi model klasifikasi berita hoaks. Prasetyo dkk. (2019) mengevaluasi penggunaan TF-IDF pada klasifikasi berita hoaks Indonesia dan menemukan bahwa representasi TF-IDF secara signifikan meningkatkan akurasi model berbasis Naïve Bayes dan SVM. Temuan serupa juga dilaporkan oleh Prasetijo dkk. (2017), yang menggabungkan TF-IDF dengan SVM dan SGD untuk mendeteksi hoaks dan mencapai akurasi sekitar 86%.

II.3.1 *Preprocessing* Teks Bahasa Indonesia



Gambar II.1 *Preprocessing* steps

Preprocessing merupakan langkah penting untuk menyiapkan teks agar dapat diproses oleh algoritma *machine learning*. Pada penelitian deteksi hoaks berbahasa Indonesia, seperti yang dilakukan Pratiwi dan Nugraha (2022), dan tahapannya tertera pada Gambar II.1. tahapan ini akan mencakup *case folding*, *cleaning*, tokenisasi, *stopword removal*, dan *stemming*. Tujuannya adalah mengubah teks mentah yang tidak seragam menjadi bentuk yang lebih terstruktur dan konsisten sehingga fitur yang diekstraksi pada tahap berikutnya benar-benar mencerminkan isi dokumen.

1. **Case folding**

Case folding adalah proses mengubah seluruh huruf dalam teks menjadi huruf kecil. Langkah sederhana ini mencegah model membedakan kata yang sama hanya karena perbedaan kapitalisasi, misalnya “Hoaks”, “hoaks”, dan “HO-AKS”. Dengan case folding, ketiga bentuk tersebut dipandang sebagai satu token yang sama sehingga distribusi kata menjadi lebih stabil.

2. **Cleaning**

Cleaning bertujuan menghilangkan elemen teks yang tidak relevan untuk analisis isi. Pada tahap ini biasanya dihapus karakter non-alfabet, angka, tanda baca tertentu, URL, alamat email, hingga simbol atau emoji yang tidak diperlukan. Dalam konteks berita hoaks Indonesia, banyak teks yang mengandung tautan ke laman lain, tag media sosial, atau karakter khusus dari proses penyalinan. Pembersihan ini membantu mengurangi *noise* sehingga model tidak terganggu oleh token yang tidak bermakna.

3. **Tokenisasi**

Tokenisasi adalah proses memecah teks yang telah dibersihkan menjadi satuan kata (token). Tokenisasi biasanya dilakukan berdasarkan spasi atau tanda baca sehingga setiap kata menjadi unit analisis tersendiri. Misalnya, kalimat “Berita ini ternyata hoaks” akan dipecah menjadi token [”berita”, ”ini”, ”ternyata”, ”hoaks”].

4. **Stopword removal**

Stopword removal menghapus kata-kata yang sangat sering muncul tetapi tidak membantu membedakan dokumen. Kata seperti ”yang”, ”adalah”, ”itu”, ”dan”, atau ”untuk” biasanya dimasukkan ke dalam daftar stopwords bahasa Indonesia. Dengan menghilangkan kata-kata ini, model dapat lebih fokus pada kata yang membawa makna spesifik. Pratiwi dan Nugraha (2022) juga menggunakan daftar stopwords Indonesia sebagai bagian dari *pipeline prepro-*

cessing mereka.

5. Stemming

Stemming mereduksi kata ke bentuk dasarnya. Bahasa Indonesia memiliki struktur morfologi yang kaya, sehingga algoritma seperti Nazief–Adriani atau pustaka Sastrawi banyak digunakan. Sebagai contoh, kata ”mempunyai”, ”kepunyaan”, dan ”punya” akan distem menjadi bentuk dasar ”punya”. Dengan stemming, variasi kata yang berasal dari akar yang sama tidak dipandang sebagai token berbeda sehingga distribusi fitur menjadi lebih padat dan lebih mudah dipelajari oleh model.

Rangkaian tahapan ini menjadi pola umum pada berbagai penelitian deteksi hoaks Indonesia dan terbukti meningkatkan kualitas representasi teks sebelum masuk ke tahap ekstraksi fitur.

II.3.2 Representasi Fitur TF-IDF

Setelah proses *preprocessing* selesai, teks yang telah bersih dan terstruktur perlu diubah menjadi bentuk numerik agar dapat diproses oleh algoritma *machine learning*. Salah satu metode yang paling banyak digunakan adalah *Term Frequency-Inverse Document Frequency* (TF-IDF). Representasi ini memberikan bobot pada setiap kata berdasarkan frekuensi kemunculannya dalam dokumen dan seberapa jarang kata tersebut muncul di seluruh korpus.

Term Frequency (TF)

Term Frequency mengukur frekuensi relatif kata w dalam dokumen d . Rumus umum TF adalah:

$$TF(w, d) = \frac{\text{count}(w \in d)}{\text{total kata pada } d} \quad (\text{II.1})$$

Keterangan: w = kata tertentu, d = dokumen, $\text{count}(w \in d)$ = jumlah kemunculan kata w dalam dokumen.

Inverse Document Frequency (IDF)

IDF mengukur seberapa jarang kata muncul dalam korpus. Rumus IDF dicatat dalam bentuk:

$$IDF(w) = \log \left(\frac{N}{df(w)} \right) \quad (II.2)$$

Keterangan: N = jumlah total dokumen, $df(w)$ = jumlah dokumen yang mengandung kata w .

Bobot TF-IDF

Bobot TF-IDF diperoleh dengan mengalikan TF dan IDF:

$$TFIDF(w, d) = TF(w, d) \times IDF(w) \quad (II.3)$$

Nilai TF-IDF akan tinggi ketika sebuah kata sering muncul pada satu dokumen, tetapi jarang muncul di dokumen lain. Kondisi ini menunjukkan bahwa kata tersebut memiliki daya diskriminasi tinggi dan penting untuk membedakan dokumen. Sebaliknya, kata yang muncul di hampir semua dokumen akan memiliki nilai TF-IDF rendah karena dianggap kurang informatif. Dengan cara ini, setiap dokumen direpresentasikan sebagai vektor berdimensi tinggi yang berisi bobot TF-IDF untuk setiap kata yang dipertahankan setelah *preprocessing*.

Berbagai penelitian deteksi hoaks Indonesia seperti Prasetyo dkk. (2019), Pratiwi dan Nugraha (2022), dan Sihombing (2020) menunjukkan bahwa representasi TF-IDF memberikan performa stabil dan efektif ketika dipadukan dengan algoritma *machine learning* klasik seperti Naïve Bayes dan SVM. Hal ini menjadi salah satu alasan utama penggunaan TF-IDF dalam tugas akhir ini.

II.3.3 Justifikasi Penggunaan Representasi TF-IDF

Pemilihan TF-IDF sebagai metode representasi teks dalam penelitian ini didasarkan pada pertimbangan metodologis dan bukti empiris dari berbagai penelitian deteksi hoaks berbahasa Indonesia. TF-IDF menawarkan pendekatan yang sederhana namun efektif untuk menonjolkan kata yang memiliki nilai diskriminatif tinggi dalam suatu dokumen. Representasi ini memberikan bobot lebih besar pada kata yang sering muncul dalam satu teks tetapi jarang ditemukan pada teks lain dalam korpus. Dengan cara ini, model dapat lebih mudah membedakan pola bahasa antara berita hoaks dan non-hoaks. Kesederhanaan struktur TF-IDF juga menjadikannya lebih mudah diinterpretasikan dibandingkan representasi lain, sehingga sesuai untuk penelitian yang memfokuskan diri pada algoritma *machine learning* klasik dan

kebutuhan evaluasi yang transparan.

Alternatif representasi seperti Word2Vec dan GloVe mampu menangkap hubungan semantik antarkata melalui vektor kontinu, sementara *embedding* kontekstual seperti BERT atau IndoBERT memberikan representasi yang jauh lebih kaya. Namun pendekatan tersebut membutuhkan proses pelatihan tambahan, sumber daya komputasi lebih besar, serta kompleksitas dalam pengaturan hiperparameter. Dalam konteks tugas akhir ini yang menggunakan *dataset* berukuran sedang dan berfokus pada perbandingan tiga algoritma klasik, penggunaan *embedding* canggih tidak sejalan dengan batasan ruang lingkup Tugas Akhir. Selain itu, penggunaan representasi yang lebih kompleks dapat memengaruhi interpretabilitas hasil, terutama ketika tujuan Tugas Akhir mencakup penyediaan *baseline* yang stabil untuk penelitian lanjutan.

Efektivitas TF-IDF dalam deteksi hoaks bahasa Indonesia juga didukung oleh hasil empiris dari berbagai penelitian sebelumnya. Prasetyo dkk. (2019) menunjukkan bahwa penggunaan TF-IDF secara konsisten meningkatkan akurasi model Naïve Bayes dan SVM dalam mengklasifikasikan berita hoaks. Penelitian Sihombing (2020) menemukan bahwa kombinasi TF-IDF dan SVM mampu mencapai akurasi lebih dari 90 persen pada *dataset* berita daring Indonesia. Hasil serupa terlihat pada penelitian Pratiwi dan Nugraha (2022) yang menggunakan TF-IDF untuk memetakan fitur teks pada *dataset* berita hoaks berbahasa Indonesia, serta penelitian lain seperti Prasetyo dkk. (2017) dan Triyono dkk. (2023), yang memperlihatkan stabilitas performa TF-IDF dalam berbagai model *machine learning* klasik. Konsistensi ini memperkuat justifikasi bahwa TF-IDF merupakan representasi yang tidak hanya efisien, tetapi juga mampu memberikan hasil kompetitif pada berbagai *dataset* hoaks Indonesia.

Berdasarkan pertimbangan tersebut, TF-IDF menjadi pilihan yang paling relevan untuk Tugas Akhir ini. Metode ini mendukung kebutuhan analisis yang efisien, dapat diinterpretasikan, dan sejalan dengan pendekatan *machine learning* klasik yang digunakan. Penggunaan TF-IDF juga memastikan bahwa hasil Tugas Akhir dapat dibandingkan secara langsung dengan studi terdahulu sehingga memberikan dasar yang kuat bagi pengembangan model deteksi hoaks pada tahap selanjutnya.

II.3.4 Representasi Fitur Sumber dengan One-Hot *encoding*

Pemanfaatan fitur sumber dalam Tugas Akhir ini berangkat dari asumsi bahwa pola hoaks tidak hanya muncul pada isi teks, tetapi juga dapat dipengaruhi oleh karakte-

ristik asal berita, seperti domain situs atau jenis media tempat artikel dipublikasikan. Informasi tersebut bersifat kategorikal dan tidak dapat langsung digunakan sebagai masukan bagi algoritma klasifikasi yang mengharuskan representasi numerik. Oleh karena itu, diperlukan proses *encoding* agar fitur sumber dapat diperlakukan sebagai bagian dari vektor fitur yang diproses oleh model.

Penelitian Herdian, Kamila, dan Budidarma (2024) tersebut menguji dua teknik *encoding* utama yang lazim digunakan pada data kategorikal. Label *encoding* merepresentasikan setiap kategori sebagai bilangan integer yang berbeda, namun cara ini secara implisit menimbulkan hubungan ordinal antar kategori meskipun dalam kenyataannya kategori tersebut tidak memiliki urutan. Sebaliknya, one-hot *encoding* menghasilkan vektor biner untuk setiap kategori dan tidak mengasumsikan adanya hubungan berjenjang antar nilai kategorikal. Pendekatan ini umumnya lebih aman untuk variabel nominal karena tidak memperkenalkan struktur matematis yang tidak sesuai dengan makna datanya.

Hasil penelitian Herdian, Kamila, dan Budidarma (2024) menunjukkan bahwa pemilihan teknik *encoding* berpengaruh terhadap performa model. One-hot *encoding* menghasilkan nilai R-squared 0.85, jauh lebih tinggi dibanding label *encoding* yang hanya mencapai 0.54, sehingga model yang memanfaatkan one-hot *encoding* mampu merepresentasikan data kategorikal dengan lebih tepat dalam konteks pemodelan yang mereka bangun. Temuan ini menguatkan prinsip umum dalam *Feature Engineering* bahwa variabel kategorikal nominal sebaiknya direpresentasikan dengan *encoding* yang tidak menambahkan asumsi hierarki antar kategori.

Dalam konteks Tugas Akhir deteksi hoaks ini, fitur sumber seperti domain situs atau kategori media memiliki sifat nominal dan jumlah kategorinya relatif terbatas setelah proses pemetaan. Berdasarkan pertimbangan tersebut serta temuan dari studi sebelumnya, penelitian ini menggunakan *one-hot encoding* untuk merepresentasikan fitur sumber. Teknik ini memungkinkan model memanfaatkan informasi sumber tanpa menambahkan struktur numerik yang tidak relevan. Selain itu, fitur seperti nama penulis tidak dimasukkan karena jumlah kategorinya sangat besar dan berpotensi menambah noise tanpa kontribusi signifikan terhadap akurasi model.

II.4 Algoritma Naïve Bayes, SVM, dan Random Forest untuk Klasifikasi Teks

II.4.1 Naïve Bayes

Naïve Bayes merupakan salah satu algoritma klasifikasi yang banyak digunakan dalam analisis teks karena kesederhanaan dan performanya yang stabil pada data berdimensi tinggi. Secara teoritis, model ini didasarkan pada Teorema Bayes yang memodelkan probabilitas posterior suatu kelas C terhadap dokumen teks d . Teorema Bayes secara umum dirumuskan sebagai:

$$P(C | d) = \frac{P(d | C) P(C)}{P(d)} \quad (\text{II.4})$$

Keterangan: $P(C | d)$ = probabilitas posterior kelas C diberikan dokumen d , $P(d | C)$ = probabilitas likelihood dokumen d diberikan kelas C , $P(C)$ = probabilitas prior kelas C ,

Dalam konteks klasifikasi teks, dokumen direpresentasikan sebagai sekumpulan kata sehingga probabilitas dokumen diberikan kelas diturunkan dari probabilitas kemunculan kata-kata tersebut dalam kelas. Naïve Bayes menggunakan asumsi independensi antar fitur, yaitu setiap kata dianggap tidak saling bergantung satu sama lain apabila kelasnya diketahui. Meskipun asumsi ini tidak sepenuhnya realistis untuk bahasa natural, berbagai penelitian menunjukkan bahwa model ini tetap efektif, sehingga sering disebut sebagai "naïve yet effective".

Varian Naïve Bayes yang paling umum digunakan untuk teks adalah *Multinomial Naïve Bayes*, yang menghitung probabilitas berdasarkan frekuensi kemunculan kata dalam dokumen. Rumus prediksi kelas pada varian ini dapat dituliskan sebagai:

$$P(C | d) \propto P(C) \prod_{i=1}^n P(w_i | C) \quad (\text{II.5})$$

dengan w_i adalah kata ke- i dalam dokumen. Pada tahap pelatihan, model menghitung probabilitas prior kelas berdasarkan distribusi kelas dan probabilitas bersyarat $P(w_i | C)$ dari frekuensi kata pada kelas tersebut. Pada tahap prediksi, probabilitas posterior dihitung untuk setiap kelas, dan kelas dengan nilai tertinggi dipilih sebagai hasil klasifikasi.

Keunggulan Naïve Bayes terletak pada kesederhanaan dan efisiensi komputasinya. Waktu pelatihan bersifat linear terhadap jumlah fitur, sehingga sangat sesuai untuk

data teks yang *sparse* dengan jumlah fitur besar. Selain itu, probabilitas kata yang dihasilkan memberikan interpretabilitas yang baik, memungkinkan peneliti mengidentifikasi kata yang paling berpengaruh terhadap prediksi model. Algoritma ini juga memiliki jumlah hiperparameter yang minimal sehingga cocok digunakan sebagai *baseline* sebelum mencoba model yang lebih kompleks.

Namun demikian, Naïve Bayes memiliki keterbatasan, seperti asumsi independensi kata yang membuat model kurang mampu menangkap hubungan semantik antar kata. Model ini juga cenderung kalah performa dibandingkan algoritma lain seperti SVM atau Random Forest pada data dengan pola bahasa yang lebih kompleks. Selain itu, terdapat risiko *zero probability* ketika suatu kata tidak pernah muncul pada kelas tertentu, yang umumnya diatasi menggunakan teknik smoothing seperti *Laplace smoothing*.

Dalam konteks deteksi hoaks berbahasa Indonesia, Naïve Bayes tetap relevan karena hoaks sering menampilkan pola linguistik yang khas, seperti penggunaan kata-kata emosional dan struktur kalimat yang sederhana. Pratiwi dan Nugraha (2022) menunjukkan bahwa Multinomial Naïve Bayes yang dipadukan dengan TF-IDF mampu mencapai akurasi sekitar 71% dengan nilai *precision*, *recall*, dan F1-score di atas 70% pada *dataset* berita hoaks Indonesia. Studi lain oleh Cahyono dkk. (2024) juga melaporkan bahwa model berbasis Naïve Bayes bekerja efisien dalam mendeteksi hoaks terkait COVID-19 pada media sosial, terutama dalam kondisi yang membutuhkan prediksi cepat. Penelitian Prasetyo dkk. (2019) turut menunjukkan bahwa penggunaan TF-IDF mampu meningkatkan performa Naïve Bayes secara signifikan pada klasifikasi hoaks Indonesia.

Berbagai pengembangan Naïve Bayes juga telah dilakukan untuk meningkatkan performanya. Varian *Complement Naïve Bayes* dirancang untuk menangani ketidakseimbangan kelas yang sering muncul pada *dataset* hoaks, sedangkan *Bernoulli Naïve Bayes* digunakan ketika fitur direpresentasikan dalam bentuk biner. Namun, untuk tugas akhir ini, Multinomial Naïve Bayes dipilih karena paling sesuai dengan representasi fitur TF-IDF dan karakteristik data teks berita yang berbasis frekuensi kata.

II.4.2 Support Vector Machine (SVM)

Support Vector Machine (SVM) merupakan salah satu algoritma yang banyak digunakan untuk tugas klasifikasi teks karena kemampuannya menemukan batas pemisah yang optimal antara dua kelas dalam ruang fitur berdimensi tinggi. Intuisi

dasar SVM adalah mencari sebuah *hyperplane* yang dapat memisahkan data dengan margin terbesar, yaitu jarak antara *hyperplane* dan titik-titik terdekat dari masing-masing kelas. Dalam representasi TF-IDF yang digunakan pada Tugas Akhir ini, setiap dokumen diproyeksikan ke ruang fitur berukuran sangat besar, sering kali mencapai ribuan dimensi. Karakteristik ini sesuai dengan SVM karena algoritma ini dirancang untuk bekerja optimal pada data *sparse* berdimensi tinggi.

Formulasi dasar SVM untuk kasus linear dapat dinyatakan sebagai permasalahan optimisasi untuk meminimalkan norma vektor bobot. Tujuannya adalah memperoleh *hyperplane* dengan margin maksimum:

$$\min \frac{1}{2} \|w\|^2 \quad (\text{II.6})$$

dengan constraint:

$$y_i(w \cdot x_i + b) \geq 1, \quad \forall i = 1, \dots, n \quad (\text{II.7})$$

dengan w sebagai vektor normal *hyperplane*, b adalah bias, x_i adalah vektor fitur dokumen, dan y_i merupakan label kelas.

Ketika data tidak dapat dipisahkan secara sempurna, SVM menggunakan pendekatan *soft margin* dengan menambahkan variabel slack ξ_i dan parameter regularisasi C untuk mengontrol keseimbangan antara margin dan kesalahan klasifikasi:

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (\text{II.8})$$

Untuk menangani data non-linear, SVM menggunakan teknik *kernel* yang memetakan fitur ke ruang berdimensi lebih tinggi melalui fungsi seperti *linear*, *polynomial*, atau Radial Basis Function (RBF). *Kernel trick* memungkinkan komputasi dilakukan tanpa eksplisit menghitung transformasi ke ruang baru.

Keunggulan utama SVM terletak pada kemampuannya bekerja sangat baik di ruang fitur besar dan *sparse*, karakteristik umum pada representasi TF-IDF. SVM juga cenderung memiliki generalisasi yang baik karena prinsip margin maximization yang mengurangi risiko overfitting. Selain itu, hanya sebagian kecil sampel menjadi *support vectors*, sehingga model fokus pada titik-titik yang paling menentukan pemi-

lahan kelas. Fleksibilitas *kernel* memungkinkan adaptasi terhadap pola non-linear, meskipun untuk data teks umumnya kernel linear sudah optimal.

Namun SVM memiliki keterbatasan, seperti proses pelatihan yang dapat menjadi lambat pada *dataset* sangat besar karena membutuhkan solusi optimisasi kuadratik. Model ini juga membutuhkan penentuan hiperparameter seperti jenis kernel, nilai C , serta parameter lain seperti γ pada kernel RBF. Selain itu, SVM tidak secara alami menghasilkan probabilitas sehingga memerlukan kalibrasi apabila probabilitas diperlukan. Interpretabilitas SVM juga lebih rendah dibandingkan Naïve Bayes yang menunjukkan kontribusi kata secara langsung.

Dalam konteks deteksi hoaks bahasa Indonesia, SVM terbukti sangat relevan. Representasi TF-IDF untuk berita hoaks cenderung membentuk pemisahan kelas yang jelas karena hoaks sering menunjukkan pola linguistik seperti repetisi, kata emosional, dan struktur sederhana. Sihombing (2020) menunjukkan bahwa SVM dengan TF-IDF mampu mencapai akurasi lebih dari 90% dalam klasifikasi berita hoaks Indonesia. Penelitian Prasetijo dkk. (2017) juga melaporkan bahwa SVM dan teknik SGD memberikan performa kompetitif pada *dataset* berita hoaks dari situs daring Indonesia. Triyono dkk. (2023) serta studi lain seperti Safira dan Nurlayli (2023) menunjukkan pola hasil yang konsisten bahwa SVM sering berada pada peringkat teratas dalam akurasi dan F1-score untuk deteksi hoaks Indonesia.

Dari sisi implementasi, penggunaan kernel linear umumnya sudah memadai untuk tugas teks karena ruang fitur TF-IDF cenderung hampir linear separable. Parameter C biasanya dioptimalkan menggunakan *cross-validation* untuk mencapai keseimbangan antara margin yang luas dan kesalahan klasifikasi yang kecil. Perangkat lunak seperti `libsvm` atau `SVC` dari `scikit-learn` banyak digunakan karena menyediakan solver efisien untuk *dataset* teks. Berdasarkan karakteristik ini, SVM menjadi salah satu algoritma yang sangat kuat dan relevan untuk deteksi hoaks pada Tugas Akhir ini.

II.4.3 Random Forest

Random Forest merupakan algoritma berbasis *ensemble learning* yang menggabungkan banyak pohon keputusan untuk menghasilkan model klasifikasi yang lebih stabil dan akurat. Intuisi dasarnya adalah bahwa banyak model sederhana yang dilatih secara terpisah pada variasi data yang berbeda dapat memberikan prediksi yang lebih baik ketika digabungkan. Pada algoritma ini, setiap pohon keputusan dianggap sebagai *weak learner*, namun ketika digabungkan melalui mekanisme voting, kese-

luruhan sistem menjadi *strong learner* yang mampu melakukan klasifikasi dengan generalisasi yang baik. Pendekatan ensemble ini relevan dalam pemrosesan teks, termasuk deteksi hoaks, karena pola linguistik hoaks sering kali tidak ditentukan oleh satu fitur saja, melainkan oleh kombinasi banyak sinyal kecil yang terdistribusi di seluruh dokumen.

Proses pembelajaran Random Forest dilakukan dengan teknik *bagging* atau *bootstrap aggregating*, di mana setiap pohon dilatih menggunakan sampel bootstrap dari *dataset* pelatihan. Pada setiap node dalam pohon, hanya sebagian acak fitur yang dipertimbangkan dalam proses pemilihan. Mekanisme ini sengaja dirancang untuk menurunkan korelasi antar pohon sehingga hasil agregasi lebih stabil. Untuk klasifikasi, prediksi akhir ditentukan melalui voting mayoritas berdasarkan prediksi tiap pohon dalam ensemble. Secara formal, prediksi akhir dapat dituliskan sebagai:

$$\hat{y} = \arg \max_c \sum_{i=1}^T I(h_i(x) = c) \quad (\text{II.9})$$

dengan $h_i(x)$ adalah prediksi pohon ke- i , T jumlah total pohon, dan $I(\cdot)$ fungsi indikator yang bernilai 1 jika ekspresi di dalamnya benar dan 0 jika salah. Selama pelatihan, sebagian sampel tidak terpilih dalam proses bootstrap sehingga dapat digunakan sebagai *out-of-bag estimation* sebagai perkiraan kesalahan generalisasi tanpa memerlukan data validasi terpisah. Random Forest juga menyediakan pengukuran *feature importance* melalui penurunan impurity (misalnya berbasis Gini atau entropi), sehingga peneliti dapat melihat fitur mana yang paling berkontribusi terhadap keputusan klasifikasi.

Keunggulan Random Forest antara lain adalah ketahanannya terhadap *noise* dan *outlier* karena agregasi banyak pohon dapat meredam kesalahan dari pohon individual. Model ini juga mampu menangkap pola non-linear yang kompleks karena struktur pohon keputusan memungkinkan pembentukan aturan yang fleksibel. Selain itu, Random Forest relatif mudah digunakan karena tidak membutuhkan banyak penyesuaian hiperparameter; jumlah pohon dan kedalaman maksimum biasanya sudah cukup untuk memberikan performa yang baik pada *dataset* berukuran kecil hingga menengah. Proses pelatihannya dapat diparalelkan karena setiap pohon dibangun secara independen, sehingga efisien untuk *dataset* teks berukuran moderat yang menjadi fokus Tugas Akhir ini.

Di sisi lain, Random Forest memiliki beberapa keterbatasan. Model ini lebih sulit diinterpretasikan dibandingkan satu pohon keputusan tunggal karena prediksi merupakan hasil agregasi dari banyak pohon. Waktu inferensi juga dapat lebih lambat dibandingkan Naïve Bayes atau pohon keputusan tunggal karena setiap prediksi melibatkan seluruh pohon dalam ensemble. Selain itu, model dapat memerlukan memori yang lebih besar apabila jumlah pohon banyak dan setiap pohon tumbuh cukup dalam. Meskipun demikian, kompromi ini umumnya sebanding dengan peningkatan akurasi yang diperoleh.

Dalam konteks deteksi hoaks berbahasa Indonesia, Random Forest menunjukkan performa yang kompetitif. Triyono dkk. (2023) menunjukkan bahwa Random Forest memberikan akurasi dan F1-score yang stabil pada *dataset* berita hoaks Indonesia dan sering menjadi salah satu model dengan kinerja terbaik dalam perbandingan antar algoritma. Studi Safira dan Nurlayli (2023) juga memperlihatkan bahwa Random Forest unggul dalam stabilitas prediksi pada berbagai skema validasi, khususnya pada *dataset* berukuran menengah yang lazim dalam penelitian hoaks lokal. Selain itu, Alguttar, Shaaban, dan Yildirim (2024) dalam konteks deteksi berita palsu menggarisbawahi keunggulan Random Forest pada *dataset* teks yang tidak terlalu besar, terutama dalam menghadapi ketidakseimbangan kelas dan variasi pola linguistik yang kompleks.

Dari sisi implementasi praktis, jumlah pohon (*n_estimators*) umumnya berada pada kisaran 100 hingga 500, sementara peningkatan jumlah pohon di atas 200 biasanya hanya memberikan perbaikan performa yang semakin kecil. Parameter lain seperti *max_depth* dan *max_features* dapat disesuaikan untuk mengontrol kompleksitas model dan penggunaan memori. Pada representasi TF-IDF dengan ribuan fitur, penggunaan nilai *default* pada pustaka seperti *scikit-learn* sering kali sudah cukup efektif. Dengan mempertimbangkan karakteristik ensemble, fleksibilitas aturan pohon keputusan, serta performa yang stabil pada berbagai penelitian sebelumnya, Random Forest menjadi salah satu algoritma yang layak digunakan dalam analisis komparatif pada tugas akhir ini.

II.5 Metrik Evaluasi Kinerja Model

Evaluasi kinerja model merupakan bagian penting dalam proses klasifikasi teks, terutama pada tugas deteksi hoaks yang memiliki konsekuensi langsung terhadap kualitas informasi dan penyebaran berita palsu. Penilaian kinerja tidak hanya melihat seberapa sering model membuat prediksi yang benar, tetapi juga mempertimbangk-

an jenis kesalahan yang terjadi. Dalam konteks berita hoaks, kesalahan tertentu seperti tidak terdeteksinya hoaks berbahaya dapat berdampak lebih besar dibandingkan salah mengklasifikasikan berita asli. Oleh karena itu, pemahaman mendalam mengenai Confusion Matrix dan metrik turunannya sangat diperlukan untuk memberikan gambaran yang komprehensif mengenai performa model. Literatur *machine learning* seperti Alghamdi, Lin, dan Luo (2022) dan Alghamdi, Luo, dan Lin (2024) menjadikan Confusion Matrix sebagai dasar evaluasi model klasifikasi karena struktur dan interpretasinya yang jelas pada kasus biner.

II.5.1 Confusion Matrix dan Komponen Dasarnya

Confusion matrix merupakan alat evaluasi yang digunakan untuk melihat performa model klasifikasi dengan membandingkan hasil prediksi terhadap label aktual. Untuk klasifikasi biner seperti deteksi hoaks, Confusion Matrix berbentuk tabel 2×2 yang berisi empat komponen utama: True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN). Secara ringkas, struktur Confusion Matrix dapat dituliskan sebagai:

Tabel II.1 Confusion matrix untuk klasifikasi biner deteksi hoaks

	Prediksi Hoaks	Prediksi Non-hoaks
Aktual Hoaks	TP	FN
Aktual Non-hoaks	FP	TN

TP terjadi ketika model memprediksi sebuah berita sebagai hoaks dan label aktualnya memang hoaks. TN muncul ketika model memprediksi berita sebagai non-hoaks dan labelnya benar. FP merupakan kondisi ketika model salah mengklasifikasikan berita asli sebagai hoaks, sedangkan FN terjadi ketika berita hoaks salah diprediksi sebagai berita asli.

Dalam konteks deteksi hoaks Indonesia, FP yang tinggi dapat menyebabkan berita asli ditandai sebagai hoaks sehingga merusak kepercayaan publik terhadap sistem deteksi. Sementara itu, FN jauh lebih berbahaya karena hoaks dapat lolos dan menyebar lebih jauh tanpa terdeteksi. Studi seperti Triyono dkk. (2023) dan Safira dan Nurlyli (2023) menekankan risiko FN dalam sistem deteksi hoaks karena dampaknya yang signifikan terhadap penyebaran misinformasi.

II.5.2 Metrik Kinerja dari Confusion Matrix

Berbagai metrik evaluasi diturunkan dari Confusion Matrix untuk menilai performa model secara kuantitatif. Metrik paling dasar adalah akurasi, yang mengukur

proporsi prediksi benar terhadap keseluruhan prediksi:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (II.10)$$

Meskipun mudah dipahami, akurasi tidak selalu mencerminkan performa sebenarnya, terutama pada *dataset* tidak seimbang. Model yang selalu memprediksi “non-hoaks” dapat memperoleh akurasi tinggi tanpa memberikan kemampuan deteksi hoaks yang berarti.

Metrik berikutnya adalah **precision**, yang mengukur seberapa besar proporsi prediksi hoaks yang benar-benar merupakan hoaks:

$$Precision = \frac{TP}{TP + FP} \quad (II.11)$$

Precision tinggi berarti ketika model menandai berita sebagai hoaks, prediksi tersebut sangat mungkin benar. Dalam konteks Indonesia, precision penting untuk menghindari situasi di mana berita asli terlalu sering diklasifikasikan sebagai hoaks.

Recall atau sensitivitas mengukur seberapa banyak berita hoaks yang berhasil ditangkap model:

$$Recall = \frac{TP}{TP + FN} \quad (II.12)$$

Recall tinggi penting untuk meminimalkan FN, yakni ketika model gagal mendeteksi hoaks. Dalam penyebaran hoaks yang cepat, setiap berita yang lolos dapat menyebar luas dan menimbulkan dampak negatif.

F1-score merupakan harmonic mean antara precision dan recall:

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (II.13)$$

F1-score lebih informatif dibanding akurasi ketika *dataset* tidak seimbang dan menjadi metrik utama pada penelitian-penelitian deteksi hoaks. Triyono dkk. (2023) dan

Safira dan Nurlayli (2023) menunjukkan bahwa F1-score merupakan indikator paling stabil dalam membandingkan performa berbagai algoritma, khususnya ketika distribusi kelas tidak merata.

Dalam praktik deteksi hoaks, *precision* dan *recall* sering memiliki hubungan saling bertukar—meningkatkan salah satunya biasanya menurunkan yang lain. Pada sistem *fact-checking* yang ingin menangkap sebanyak mungkin hoaks, *recall* diprioritaskan. Sebaliknya, sistem yang menghindari penandaan salah terhadap berita asli akan lebih menekankan *precision*. Pada Tugas Akhir ini, kedua metrik dianalisis secara bersamaan, sementara *F1-score* digunakan sebagai metrik ringkas untuk membandingkan tiga algoritma *machine learning* klasik yang diuji.

II.6 Penelitian Terkait

Bagian ini menguraikan penelitian terdahulu mengenai deteksi hoaks berbahasa Indonesia menggunakan pendekatan *machine learning*. Fokus diberikan pada penggunaan *preprocessing* teks, representasi TF-IDF, serta penerapan algoritma Naïve Bayes, Support Vector Machine, dan Random Forest.

II.6.1 Hoax News Identification Using Machine Learning Model from Online Media in Bahasa Indonesia (Pratiwi dan Nugraha (2022))

Penelitian ini membahas perancangan sistem deteksi hoaks menggunakan *Indonesian Hoax News Detection Dataset* yang berisi 600 artikel dari 12 topik. Pelabelan dilakukan oleh tiga anotator melalui *voting* untuk menjamin kualitas label. Tahapan *preprocessing* mencakup *case folding*, pembersihan karakter, tokenisasi, penghapusan stopwords, dan stemming menggunakan algoritma bahasa Indonesia. Fitur direpresentasikan menggunakan TF-IDF sebelum dilatih menggunakan Multinomial Naïve Bayes.

Hasil penelitian menunjukkan akurasi 71% dengan *precision*, *recall*, dan F1-score stabil di atas 70%. Studi ini memperlihatkan efektivitas Naïve Bayes sebagai *base-line* deteksi hoaks, meski belum membandingkan algoritma lain dan terbatas pada pendekatan *content-based*.

II.6.2 Evaluation of TF-IDF Feature Extraction in Indonesian Hoax News Classification (Prasetyo dkk. (2019))

Penelitian ini berfokus pada evaluasi TF-IDF sebagai metode ekstraksi fitur untuk klasifikasi hoaks. Peneliti membandingkan performa beberapa model, khususnya

Naïve Bayes dan SVM, dibandingkan dengan bag-of-words standar. *Dataset* terdiri dari berita hoaks dan non-hoaks yang telah melalui *preprocessing* dasar.

Hasilnya menunjukkan bahwa TF-IDF meningkatkan akurasi secara signifikan, terutama untuk SVM yang memperoleh peningkatan paling besar. Temuan ini memperkuat justifikasi penggunaan TF-IDF dalam penelitian deteksi hoaks Indonesia.

II.6.3 *Hoax Detection System on Indonesian News Sites Based on Text Classification Using SVM and SGD (Prasetijo dkk. (2017))*

Penelitian ini menerapkan SVM dan Stochastic Gradient Descent (SGD) untuk mendeteksi berita hoaks dari situs daring Indonesia. Fitur utama yang digunakan adalah *bigram* TF-IDF setelah *preprocessing* teks.

Eksperimen menunjukkan bahwa SVM dan SGD menghasilkan performa kompetitif, dengan akurasi mencapai 86% menggunakan SGD dengan modified-huber loss. Studi ini menjadi dasar penting yang menunjukkan efektivitas SVM pada data teks berdimensi tinggi berbahasa Indonesia.

II.6.4 *Support Vector Machine-Based Hoax Detection on Indonesian Online News (Sihombing (2020))*

Penelitian ini menegaskan kembali peran SVM dalam deteksi hoaks. *Dataset* terdiri dari artikel berita Indonesia yang diklasifikasikan sebagai hoaks atau non-hoaks. Peneliti menerapkan tokenisasi, *stopword removal*, dan *stemming* sebelum menghitung bobot TF-IDF.

Model SVM menunjukkan akurasi lebih dari 90%, menjadikannya salah satu algoritma paling efektif untuk deteksi hoaks Indonesia. Temuan ini menegaskan bahwa kombinasi *preprocessing* rapi dan TF-IDF berkontribusi besar pada performa model.

II.6.5 *Analysis and Detection of Hoax Contents in Indonesian News (Putri dkk. (2019))*

Penelitian ini membandingkan lima algoritma: Multilayer Perceptron, Naïve Bayes, SVM, Random Forest, dan Decision Tree. *Dataset* terdiri dari 251 artikel hoaks dan non-hoaks.

Hasilnya menunjukkan bahwa Random Forest memberikan akurasi tertinggi yaitu 76.47%. Hal ini menunjukkan stabilitas metode ensemble pada *dataset* kecil, serta relevansinya dalam deteksi hoaks Indonesia.

II.6.6 Indonesian Fake News Detection Using Machine Learning Techniques (Triyono dkk. (2023))

Penelitian ini menguji beberapa algoritma *machine learning* menggunakan *dataset* Kaggle berbahasa Indonesia. *Preprocessing* standar diterapkan sebelum TF-IDF digunakan sebagai representasi fitur.

Hasil penelitian menunjukkan bahwa SVM dan Random Forest konsisten memberikan performa terbaik berdasarkan akurasi dan F1-score. Studi ini menguatkan peran kedua algoritma tersebut sebagai *baseline* deteksi hoaks.

II.6.7 Comparative Analysis of Fake News Detection Using Machine Learning Models (Safira dan Nurlyli (2023))

Penelitian ini membandingkan SVM, Random Forest, Logistic Regression, dan Naïve Bayes pada *dataset* berita Indonesia berfitur TF-IDF. *Preprocessing* meliputi normalisasi teks, pembersihan karakter, dan penghapusan *stopword*.

Hasil menunjukkan bahwa SVM dan Random Forest kembali memberikan performa tertinggi. Namun penelitian ini masih terbatas pada fitur konten tanpa mempertimbangkan informasi sumber berita seperti domain atau tipe media.

II.6.8 Sintesis dan Research Gap

Dari seluruh penelitian, terlihat pola konsisten bahwa *preprocessing* dan representasi TF-IDF merupakan fondasi utama deteksi hoaks berbahasa Indonesia. Algoritma Naïve Bayes, SVM, dan Random Forest telah banyak digunakan dan menunjukkan performa berbeda bergantung *dataset*. SVM dan Random Forest umumnya unggul, sementara Naïve Bayes tetap menjadi baseline kuat.

Namun terdapat dua research gap utama:

1. **Belum ada komparasi sistematis dalam satu *pipeline* yang seragam.**
Setiap penelitian menggunakan konfigurasi berbeda sehingga hasilnya sulit dibandingkan langsung. Belum ada studi yang menguji Naïve Bayes, SVM, dan Random Forest dalam tahapan *preprocessing*, TF-IDF, pembagian data, dan evaluasi yang sama.
2. **Penelitian terdahulu masih hanya menggunakan *content-based features*.**
Tidak ada penelitian yang secara empiris menganalisis kontribusi fitur sumber seperti domain situs atau tipe media untuk meningkatkan performa deteksi hoaks.

Tugas Akhir ini dirancang untuk mengisi kedua gap tersebut dengan menyediakan perbandingan komprehensif dalam satu *pipeline* terkontrol serta mengevaluasi kontribusi fitur sumber untuk meningkatkan performa model deteksi hoaks berbahasa Indonesia.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Penyebaran berita hoaks pada *platform* berita daring di Indonesia menuntut adanya sistem deteksi otomatis yang mampu bekerja cepat dan konsisten. Kajian pada Bab II menunjukkan bahwa berbagai penelitian sebelumnya telah menggunakan algoritma *machine learning* klasik seperti Naive Bayes, SVM, dan Random Forest dengan fitur TF-IDF. Namun, hasil setiap studi masih sulit dibandingkan secara langsung karena perbedaan *dataset*, tahap pengolahan teks, serta konfigurasi model. Hal ini membuat efektivitas relatif dari ketiga algoritma tersebut belum dapat disimpulkan secara terkontrol.

Selain itu, seluruh penelitian terdahulu hanya memanfaatkan konten teks tanpa mengevaluasi kemungkinan kontribusi informasi sumber berita, seperti domain atau kategori media. Padahal, karakteristik sumber dapat menjadi indikator tambahan yang membantu model mengidentifikasi potensi hoaks. Ketiadaan evaluasi sistematis terhadap kedua aspek ini menimbulkan kebutuhan untuk merancang *pipeline* Tugas Akhir yang memungkinkan perbandingan yang adil antar algoritma sekaligus menilai pengaruh fitur sumber.

Dengan dasar tersebut, Bab III akan menjabarkan kebutuhan teknis dan desain *pipeline* yang dirancang untuk menjawab dua pertanyaan inti: bagaimana memperoleh *benchmark* yang terstandarisasi untuk NB, SVM, dan RF, serta apakah penambahan fitur sumber mampu meningkatkan performa deteksi hoaks berbahasa Indonesia.

III.2 Analisis Kebutuhan dalam Implementasi *pipeline* untuk Deteksi Hoaks

Setelah menganalisis permasalahan yang ada, menunjukkan bahwa masalah utama yang perlu diatasi adalah ketiadaan *benchmark* terkontrol untuk membandingkan

Tabel III.1 Permasalahan deteksi hoaks berita berbahasa Indonesia

Kategori Permasalahan	Inti Permasalahan
Keterbatasan Benchmark	Belum ada perbandingan NB–SVM–RF dalam satu <i>pipeline</i> yang menggunakan dataset, <i>preprocessing</i> , dan evaluasi yang sama.
Keterbatasan Fitur	Belum dievaluasi apakah fitur sumber (<i>domain/jenis media</i>) memberi kontribusi pada performa model ML klasik.
Implikasi Fitur	Pengembang dan <i>fact-checker</i> belum memiliki acuan algoritma mana yang paling sesuai untuk deteksi hoaks Indonesia.

kinerja Naïve Bayes, SVM, dan Random Forest pada berita hoaks berbahasa Indonesia, serta belum adanya evaluasi yang eksplisit terhadap pengaruh fitur sumber berita. Agar kedua celah tersebut dapat dijawab secara sistematis, dibutuhkan sebuah *pipeline* yang tidak hanya mampu menjalankan proses klasifikasi teks secara end-to-end, tetapi juga dirancang sejak awal untuk mendukung dua skenario fitur (berbasis konten saja dan berbasis konten ditambah sumber) dengan konfigurasi eksperimen yang replikabel.

Secara konseptual, *pipeline* yang dibutuhkan mengikuti alur umum pengolahan teks: memuat *dataset* berita yang telah dilabeli, melakukan *preprocessing* teks Bahasa Indonesia, membentuk representasi fitur (TF-IDF dan fitur sumber), kemudian melatih dan menguji beberapa model klasifikasi dengan metrik evaluasi yang konsisten. Di dalam alur tersebut, kebutuhan fungsional muncul dalam bentuk kemampuan sistem untuk mengelola data, memproses teks, menyusun skenario fitur, melatih model, dan menyajikan hasil komparasi. Di sisi lain, kebutuhan non-fungsional berkaitan dengan bagaimana *pipeline* tersebut dapat dijalankan secara efisien, diulang dengan hasil yang konsisten, dan menghasilkan output yang mudah diinterpretasikan oleh peneliti maupun pembimbing.

Ringkasan kebutuhan fungsional dan non-fungsional untuk *pipeline* yang diusulkan ditunjukkan pada tabel berikut.

Tabel III.2 Kebutuhan Fungsional dalam Implementasi *pipeline*

Kode	Deskripsi Kebutuhan
FR1-Pengelolaan Dataset	<i>pipeline</i> harus mampu memuat dan mengorganisasi dataset berita berbahasa Indonesia yang mencakup teks utama, label hoaks/non-hoaks, serta atribut sumber (domain atau jenis media), dan menyediakannya dalam struktur yang konsisten untuk seluruh proses eksperimen.
FR2-Preprocessing Teks	<i>pipeline</i> harus menerapkan rangkaian preprocessing teks Bahasa Indonesia secara menyeluruh, termasuk normalisasi huruf, pembersihan karakter tidak relevan, tokenisasi, stopword removal, dan stemming agar dokumen berada dalam bentuk terstandarisasi sebelum diekstraksi fiturnya.
FR3-Ekstraksi Fitur TF-IDF	<i>pipeline</i> harus mengubah teks yang sudah diproses menjadi representasi vektor TF-IDF dengan parameter yang terkontrol (token pattern, n-gram, max features) sehingga fitur yang dihasilkan seragam pada semua percobaan.
FR4-Ekstraksi Fitur Sumber	<i>pipeline</i> harus mengubah atribut sumber berita menjadi fitur numerik melalui metode encoding yang tepat (misalnya one-hot encoding), serta memastikan bahwa fitur tersebut dapat digabungkan dengan vektor TF-IDF tanpa mengubah struktur data.
FR5-Penyusunan Skenario Fitur	<i>pipeline</i> harus menyediakan dua konfigurasi fitur yang berbeda secara jelas: S1 (konten-saja) dan S2 (konten + sumber), dan memastikan bahwa kedua skenario diproses menggunakan tahapan yang identik kecuali pada komponennya yang ditambahkan.
FR6-Pelatihan dan Pengujian Model	<i>pipeline</i> harus dapat melatih dan menguji tiga algoritma machine learning klasik, Naïve Bayes, SVM, dan Random Forest. Dengan menggunakan parameter dasar yang konsisten pada kedua skenario fitur, sehingga hasil perbandingan dapat dinilai secara objektif.

Bersambung ke halaman berikutnya

Kode	Deskripsi Kebutuhan
FR7-Perhitungan Metrik Evaluasi	<i>pipeline</i> harus menghitung metrik evaluasi utama (<i>accuracy</i> , <i>precision</i> , <i>recall</i> , <i>F1-score</i>) berdasarkan confusion matrix untuk setiap kombinasi model $\times$ skenario, dan menyimpannya dalam format yang dapat diolah lebih lanjut.
FR8-Penyajian Output Komparasi	<i>pipeline</i> harus menyusun ringkasan kinerja model dalam bentuk tabel komparatif yang jelas, sehingga perbedaan performa antarmodel dan antar skenario fitur dapat dianalisis secara langsung.

Tabel III.3 Kebutuhan Non-Fungsional dalam Implementasi *pipeline*

Kode	Deskripsi Kebutuhan
NFR1-Reproducibility	<i>pipeline</i> dirancang sehingga eksperimen dapat diulang dengan hasil yang sama melalui pengaturan random seed, dokumentasi konfigurasi, dan struktur eksekusi yang deterministik.
NFR2-Efisiensi Komputasi	<i>pipeline</i> dapat dijalankan pada perangkat komputasi standar (CPU tanpa GPU) dengan waktu pemrosesan yang wajar, sehingga prosedur komparasi enam model tidak membebani sumber daya.
NFR3-Skalabilitas Moderat	<i>pipeline</i> harus tetap stabil ketika jumlah data meningkat (misalnya dari 500 menjadi >1000 artikel), tanpa memerlukan perubahan arsitektural signifikan atau penurunan performa yang drastis.
NFR4-Kemudahan Konfigurasi	<i>pipeline</i> harus memungkinkan pengaturan parameter dari model (misalnya jumlah pohon pada Random Forest) dan parameter fitur (misalnya n-gram batas TF-IDF) melalui modul konfigurasi yang mudah diubah.
NFR5-Kemudahan Interpretasi Hasil	<i>pipeline</i> harus menghasilkan laporan evaluasi yang ringkas, terstruktur, dan mudah dipahami, sehingga hasil eksperimen dapat dijelaskan kepada pembimbing atau pihak lain dengan penjelasan tersebut.

III.3 Analisis Pemilihan Pendekatan Deteksi Hoaks

Analisis kebutuhan yang dilakukan pada bagian sebelumnya menunjukkan bahwa pengembangan *pipeline* deteksi hoaks membutuhkan pendekatan yang tidak hanya sesuai dengan ruang lingkup penelitian, tetapi juga relevan dengan temuan literatur dan realistis dari sisi sumber daya komputasi. Oleh karena itu, sebelum menentukan

solusi, beberapa opsi pendekatan dievaluasi terlebih dahulu untuk melihat kesesuaiannya dengan permasalahan dan gap penelitian yang telah dirumuskan.

III.3.1 Alternatif Pendekatan Umum yang Dapat Digunakan

Secara umum, terdapat tiga kategori pendekatan yang sering digunakan dalam penelitian deteksi hoaks. Pendekatan berbasis Deep Learning atau Transformer, seperti IndoBERT, menawarkan performa tinggi dan kemampuan memahami konteks bahasa yang lebih kompleks, tetapi memerlukan *dataset* besar dan perangkat GPU, sehingga tidak sesuai dengan batasan Tugas Akhir ini.

Pendekatan kedua adalah metode *machine learning* klasik berbasis konten dengan fitur TF-IDF, menggunakan algoritma seperti Naïve Bayes, SVM, dan Random Forest. Pendekatan ini banyak digunakan pada penelitian hoaks berbahasa Indonesia, efisien secara komputasi, dan mudah direplikasi, sehingga sering dijadikan baseline dalam studi komparatif.

Pendekatan ketiga memperluas metode klasik dengan menambahkan metadata sederhana, seperti informasi sumber berita (misalnya domain atau jenis media). Penambahan fitur ini menawarkan kemungkinan untuk menangkap sinyal kredibilitas yang tidak terlihat pada teks murni, meskipun belum banyak diuji secara sistematis dalam penelitian terdahulu.

Berikut tabel yang menunjukkan perbandingan pendekatan tersebut.

Tabel III.4 Perbandingan pendekatan untuk deteksi hoaks

Pendekatan	Kelebihan	Keterbatasan
Deep learning / Transformer	Representasi semantik kuat, hasil unggul di <i>dataset</i> besar	Membutuhkan GPU dan <i>dataset</i> besar; tidak sesuai batasan TA
ML klasik berbasis konten (TF-IDF)	Efisien, stabil, banyak dipakai dalam penelitian hoaks Indonesia	Terbatas pada teks; tidak menangkap konteks sumber
ML klasik + metadata (mis. source)	Menambah sinyal kredibilitas media; ruang lingkup tetap terbatas	Kualitas metadata menentukan efektivitas pendekatan

III.3.2 Pemilihan Pendekatan Deteksi Hoaks

Evaluasi terhadap ketiga pendekatan pada Tabel III.4 menunjukkan bahwa masing-masing memiliki implikasi metodologis dan operasional yang berbeda. Pendekatan

berbasis *deep learning/transformer* secara teori menawarkan performa tertinggi, namun karakteristiknya tidak sejalan dengan ruang lingkup Tugas Akhir. Model seperti IndoBERT membutuhkan ukuran *dataset* yang jauh lebih besar, proses *fine-tuning* yang kompleks, serta komputasi menggunakan GPU yang membutuhkan spesifikasi yang memadai. Selain itu, pendekatan ini tidak memberikan kontribusi langsung terhadap gap penelitian yang diidentifikasi, karena fokus Tugas Akhir bukan pada pengembangan model mutakhir, melainkan pada komparasi terkontrol metode klasik.

Pendekatan *Machine Learning* klasik berbasis konten (TF-IDF saja) merupakan alternatif yang lebih realistis dan relevan karena telah digunakan secara konsisten dalam penelitian deteksi hoaks berbahasa Indonesia. Namun pendekatan ini hanya mengandalkan sinyal linguistik dan tidak mempertimbangkan atribut eksternal yang dapat berperan sebagai indikator kredibilitas berita. Berdasarkan sintesis pada Bab II, kebanyakan penelitian sebelumnya menunjukkan kinerja yang stabil dengan TF-IDF, tetapi belum mengevaluasi kontribusi metadata, termasuk penggunaan *source*. Dengan demikian, pendekatan ini hanya dapat berfungsi sebagai *baseline*, bukan pendekatan utama untuk menjawab gap penelitian.

Pendekatan ML klasik yang diperkaya dengan metadata, dalam konteks Tugas Akhir ini, fitur sumber berita menawarkan keseimbangan antara relevansi teoretis dan kelayakan implementasi. Penambahan fitur sumber tidak mengubah struktur metodologi secara drastis, tidak menambah kebutuhan komputasi berarti, dan tetap berada dalam batasan Tugas Akhir. Pada saat yang sama, pendekatan ini membuka peluang untuk mengkaji apakah informasi eksternal sederhana dapat meningkatkan performa model, sebuah aspek yang belum dievaluasi secara sistematis oleh penelitian terdahulu. Maka dari itu, pendekatan ini akan meneliti dua gap utama yang dijadikan objek eksplorasi : tidak adanya *benchmark* NB-SVM-RF dan juga studi mengenai pengaruh fitur sumber terhadap klasifikasi hoaks berbahasa Indonesia.


Berdasarkan pertimbangan tersebut, Tugas Akhir ini menetapkan pendekatan *machine learning* klasik dengan dua konfigurasi fitur, yaitu *content-only* dan *content + source*, sebagai strategi yang paling tepat untuk menjawab permasalahan dan gap penelitian secara metodologis maupun operasional.

BAB IV

DESAIN KONSEP SOLUSI

IV.1 Gambaran Sistem/Kondisi Saat Ini (*As-Is*)

Gambar IV.1 berikut menggambarkan alur deteksi hoaks yang umum terjadi di Indonesia pada praktik sehari-hari. Pengguna membaca sebuah berita, kemudian memeriksa kredibilitasnya melalui situs *fact-checking* seperti MAFINDO/TurnBackHoax. Jika berita tersebut sudah tercatat dalam basis data, statusnya dapat diketahui sebagai hoaks atau bukan. Namun apabila belum tercatat, proses berhenti tanpa kepastian karena tidak ada mekanisme otomatis yang dapat memberikan estimasi lebih lanjut.



Gambar IV.1 Kondisi *As-Is* Alur Deteksi Hoaks di Indonesia

Penjelasan lebih lanjut mengenai kondisi saat ini menunjukkan adanya kesenjang-

an antara kebutuhan praktis dan dukungan teknologi yang tersedia. Pada penelitian yang biasa dilakukan, berbagai studi terdahulu telah menerapkan algoritma *machine learning* klasik seperti Naive Bayes, Support Vector Machine, dan Random Forest. Namun setiap penelitian menggunakan *dataset*, tahapan *preprocessing*, dan konfigurasi model yang berbeda-beda sehingga hasilnya sulit dibandingkan secara langsung. Akibatnya, hingga kini belum tersedia *benchmark* terstandarisasi yang dapat memetakan efektivitas relatif ketiga algoritma tersebut dalam konteks berita hoaks berbahasa Indonesia.

Sementara itu, praktik deteksi hoaks di lapangan masih bersifat manual. Proses verifikasi sangat bergantung pada pembaca atau *fact-checker* yang memeriksa kebenaran informasi secara langsung melalui situs pengecekan fakta. Basis data yang tersedia hanya mencakup kasus-kasus yang pernah diperiksa sebelumnya. Berita baru yang belum tercatat tetap harus dinilai secara manual, sehingga proses deteksi tidak bersifat skalabel dan tidak mampu merespons dengan cepat munculnya berita hoaks baru. Selain itu, belum ada sistem pembelajaran mesin yang mempelajari pola teks berita maupun informasi sumber (domain/jenis media) yang dapat memberikan prediksi awal secara otomatis.

Keterbatasan-keterbatasan tersebut menegaskan perlunya desain solusi Tugas Akhir yang mampu menghasilkan *benchmark* algoritma secara terstandar dan menguji secara empiris apakah penambahan fitur sumber dapat meningkatkan kemampuan model dalam mendeteksi hoaks. Bab selanjutnya akan menguraikan rancangan konsep solusi tersebut melalui pembangunan *pipeline* yang terkontrol dan *replicable*.


IV.2 Desain Konsep Solusi yang Diajukan

Konsep solusi dalam Tugas Akhir ini berupa *pipeline* eksperimen yang terstandarisasi, yang berfungsi sebagai kerangka evaluasi terukur terhadap tiga algoritma *machine learning* klasik (Naive Bayes, SVM, dan Random Forest) serta dua skenario fitur (*content-only* dan *content+source*). *Pipeline* ini dirancang untuk mereplikasi pola umum penelitian hoaks Indonesia (TF-IDF + ML klasik), sekaligus memperkenalkan blok tambahan berupa pengolahan fitur sumber berita sebagai metadata.

IV.2.1 Konsep Model Pipeline yang Diusulkan(*To-Be*)

Pipeline yang diusulkan terdiri atas beberapa komponen teknis utama yang saling terhubung secara sistematis:

1. ***Dataset***



Gambar IV.2 Kondisi *To-Be* Alur Deteksi Hoaks dengan *Pipeline* yang Diusulkan

Komponen pertama mencakup proses pemilihan, pengumpulan, dan pengorganisasian *dataset* berita hoaks dan non-hoaks berbahasa Indonesia. *Dataset* harus memuat tiga elemen penting: Pada tahap ini, data disusun dalam format yang konsisten sehingga seluruh sampel dapat melewati *pipeline* secara seragam. Manajemen *dataset* juga mengatur pembagian data ke dalam set pelatihan dan pengujian dengan mekanisme yang konsisten, sehingga hasil evaluasi antar algoritma dapat dibandingkan secara adil.

- Teks berita, yang menjadi objek utama analisis
- Label hoaks atau non-hoaks, yang menjadi target pembelajaran
- Informasi sumber seperti domain atau jenis media, yang akan digunakan sebagai fitur tambahan pada salah satu skenario.

2. **Preprocessing** Teks Bahasa Indonesia

Tahapan *preprocessing* mengikuti praktik terbaik dari penelitian-penelitian yang ada sebelumnya (Pratiwi dan Nugraha 2022; Prasetyo dkk. 2019), meliputi:

- **Case folding**, yaitu mengubah seluruh teks menjadi huruf kecil untuk menghilangkan variasi kapitalisasi yang tidak membawa makna semantik.

- **Cleaning**, yang mencakup penghapusan angka, simbol, tanda baca tertentu, *hyperlink*, dan elemen non-alfabet lain yang tidak berkontribusi pada makna isi berita.
 - **Tokenisasi**, yaitu memecah teks menjadi unit-unit kata, sehingga memungkinkan pembentukan fitur berdasarkan frekuensi dan distribusi kata.
 - **Stopword removal**, yaitu menghilangkan kata-kata umum Bahasa Indonesia yang muncul sangat sering tetapi tidak memiliki nilai diskriminatif untuk klasifikasi.
 - **Stemming**, yang mengembalikan kata ke bentuk dasarnya untuk menyatukan variasi morfologis, misalnya “menyebarkan”, “disebarkan”, dan “penyebaran” menjadi bentuk dasar “sebar”.
- Proses ini bertujuan menghasilkan representasi teks yang bersih dan dapat diproses lebih lanjut oleh model.

3. *Feature Extraction*

(a) **Fitur Konten (TF-IDF)**

TF-IDF digunakan untuk mengukur tingkat kepentingan suatu kata dalam sebuah dokumen relatif terhadap seluruh korpus. Bobot TF-IDF memastikan bahwa kata-kata yang relevan secara semantik muncul lebih dominan daripada kata umum yang kurang informatif. Representasi ini menghasilkan vektor berdimensi tinggi yang menjadi dasar utama model untuk mengenali pola linguistik khas pada berita hoaks maupun non-hoaks.

(b) **Fitur Sumber (Metadata Domain/Media)**

Informasi mengenai sumber berita, misalnya domain situs atau kategori media, dikodekan ke dalam bentuk numerik melalui teknik seperti one-hot encoding. Representasi ini memetakan setiap sumber ke dalam komponen fitur yang berbeda, memberikan kesempatan bagi model untuk mengidentifikasi kecenderungan atau pola yang berbasis sumber. Penggabungan fitur sumber dilakukan secara modular sehingga dapat dikombinasikan atau dihilangkan sesuai skenario Tugas Akhir.

Fitur-fitur ini digunakan untuk membentuk dua skenario percobaan terhadap *pipeline* yang dibangun.

4. **Penyusunan Dua Skenario Fitur**

Untuk menguji kontribusi fitur sumber terhadap performa klasifikasi, *pipeline* dirancang dengan dua skenario fitur yang diproses melalui alur identik:

- **Skenario 1 : *Content-only***

Menggunakan hanya fitur TF-IDF. Skenario ini berfungsi sebagai *baseline* dan merepresentasikan pendekatan penelitian terdahulu yang umumnya bergantung pada konten teks saja.

- **Skenario 2 : *Content + Source*** (menggabungkan TF-IDF dengan fitur sumber.)

Menggabungkan fitur TF-IDF dengan fitur sumber hasil encoding. Skenario ini memungkinkan evaluasi empiris mengenai apakah penambahan informasi sumber memberikan peningkatan performa atau tidak.

Kedua skenario ini disusun untuk memastikan bahwa efek penambahan metadata dapat dinilai secara objektif karena seluruh elemen *pipeline* selain fitur tetap sama.

5. Pelatihan Model ML Klasik

Ketiga algoritma (Naive Bayes, SVM, Random Forest) dilatih pada kedua skenario fitur. Tujuannya adalah membentuk *benchmark* performa yang konsisten dalam satu *pipeline* terkontrol.

6. Evaluasi Performa Model

Model dievaluasi menggunakan metrik standar klasifikasi *Confusion Matrix*: *accuracy*, *precision*, *recall*, *F1-score*.


Metrik ini dipilih karena telah digunakan secara konsisten dalam penelitian deteksi hoaks Indonesia (Triyono dkk. 2023; Safira dan Nurlyayli 2023).

7. *Output Benchmark* dan Analisis Pengaruh Fitur Sumber

Hasil dari kedua skenario dibandingkan untuk menilai apakah penambahan fitur sumber meningkatkan performa model secara signifikan.

Pipeline ini menjadi kerangka dasar untuk eksperimen yang *replicable* dan dapat memberikan pemahaman lebih terukur mengenai efektivitas relatif NB, SVM, dan RF, sekaligus kontribusi fitur sumber.

IV.2.2 Kondisi *To-Be*



Gambar IV.3 Kondisi *To-Be* Alur Deteksi Hoaks di Indonesia

Alur pada Gambar IV.3 menunjukkan bagaimana model yang dihasilkan dari *pipeline* Tugas Akhir ini dapat digunakan untuk memproses berita baru. Proses dimulai ketika pengguna memasukkan teks berita yang ingin diperiksa, disertai informasi sumber apabila tersedia. Berita tersebut kemudian menjalani tahapan *preprocessing* yang sama dengan tahapan saat pelatihan, sehingga konsistensi struktur data tetap terjaga dan model menerima masukan dalam format yang sesuai.

Teks yang telah melalui *preprocessing* diubah menjadi representasi numerik menggunakan TF-IDF vectorizer dan encoder fitur sumber yang sudah tertanam di dalam model. Dengan demikian, seluruh berita baru diproyeksikan ke dalam ruang fitur yang sama seperti data pelatihan. Setelah representasi fitur terbentuk, model melakukan inferensi dan menghasilkan keluaran berupa prediksi kelas hoaks atau fakta. Proses ini menggambarkan bagaimana model dapat digunakan sebagai mekanisme penyaringan awal sebelum dilakukan verifikasi manual yang lebih mendalam.

Perlu ditegaskan bahwa alur penggunaan ini merupakan ilustrasi potensi pemanfaatan model di masa mendatang. Pada tahap tugas akhir, fokus utama penggunaan model masih berada pada konteks eksperimen dan evaluasi performa dalam lingkungan yang terkontrol.

IV.3 Perbandingan Kondisi As-Is dan Konsep Solusi (*To-Be*)

Solusi yang diusulkan memberikan penyelesaian langsung terhadap berbagai keterbatasan kondisi saat ini. Tabel berikut merangkum perbandingan tersebut.

Tabel IV.1 Perbandingan kondisi saat ini dan konsep solusi yang diusulkan

Aspek	Kondisi Saat Ini	Konsep Solusi
Variasi penelitian	<i>Dataset</i> , <i>preprocessing</i> , dan konfigurasi berbeda sehingga hasil tidak dapat dibandingkan	Pipeline seragam untuk melatih dan menguji NB, SVM, dan RF
Jenis fitur	Hanya konten teks (TF-IDF)	Kombinasi TF-IDF + meta-data sumber
Metode deteksi di lapangan	Manual, tidak skalabel	Pemodelan ML sebagai <i>benchmark</i> awal
Evaluasi model	Tidak terstandarisasi	<i>Accuracy</i> , <i>precision</i> , <i>recall</i> , dan <i>F1-score</i> diterapkan dalam dua skenario
Kontribusi ilmiah	Pengetahuan terpisah antar penelitian	<i>Benchmark</i> terukur + analisis pengaruh fitur tambahan
Relevansi solusi	Tidak memberi rekomendasi algoritma terbaik	Memberi rekomendasi berbasis data untuk konteks hoaks Indonesia

Tabel III.4 merangkum perbedaan antara kondisi saat ini dan konsep solusi yang diusulkan melalui *pipeline* Tugas Akhir ini. Kondisi saat ini ditandai oleh penelitian terdahulu yang menggunakan algoritma *machine learning* klasik tetapi dengan konfigurasi, *dataset*, dan *preprocessing* yang berbeda-beda, sehingga hasilnya sulit dibandingkan secara langsung. Di sisi praktik lapangan, deteksi hoaks masih sangat bergantung pada verifikasi manual serta basis data yang terbatas pada kasus yang sudah pernah diperiksa, tanpa adanya model prediktif yang dapat memberikan estimasi awal untuk berita baru.

Konsep solusi yang diusulkan menyediakan kerangka eksperimen yang terstandarisasi melalui *pipeline* yang menerapkan *dataset* konsisten, *preprocessing* yang seragam, dua skenario fitur yang terkontrol, serta evaluasi kinerja menggunakan metrik yang sama untuk semua model. Pendekatan ini menghasilkan *benchmark* yang dapat dibandingkan secara adil antar algoritma serta memungkinkan analisis empiris mengenai pengaruh penambahan fitur sumber terhadap performa deteksi.

Keberadaan detector model dan alur penggunaan pada Gambar IV.3 menunjukkan

bahwa *pipeline* yang dirancang tidak hanya berfungsi sebagai alat evaluasi, tetapi juga membuka peluang pengembangan model sebagai komponen *screening* otomatis bagi berita baru di masa mendatang. Dengan demikian, konsep solusi ini menjembatani kesenjangan antara kebutuhan praktis deteksi hoaks dan fragmentasi hasil penelitian sebelumnya.

BAB V

RENCANA SELANJUTNYA

V.1 Rencana Implementasi

V.1.1 Langkah Implementasi

Rencana implementasi pada Tugas Akhir ini disusun untuk menerjemahkan desain *pipeline* konseptual pada IV ke dalam langkah-langkah kerja yang terstruktur. Setiap tahap dirancang agar dapat direplikasi, mudah ditelusuri, dan menghasilkan artefak yang konsisten untuk proses evaluasi. Tabel V.1 merangkum keseluruhan proses implementasi berdasarkan urutan waktu, lingkup kegiatan, serta keluaran yang diharapkan.

Tabel V.1 Rencana Implementasi

Periode	Tahap	Deskripsi Kegiatan	Output
Minggu 1-2	Penyusunan <i>Dataset</i>	Mengumpulkan berita berlabel hoaks/non-hoaks dan atribut sumber. Membersihkan data dari duplikasi, entri kosong, dan data tidak relevan. Menyusun <i>dataset</i> terstruktur dalam format yang seragam.	<i>Dataset</i> terstruktur berisi teks, label, dan <i>domain/kategori</i> .

Bersambung ke halaman berikutnya

Tabel V.1 Rencana Implementasi (lanjutan)

Periode	Tahap	Deskripsi Kegiatan	Output
Minggu 3	<i>Preprocessing</i> Teks	Membangun modul <i>preprocessing</i> (<i>case folding</i> , <i>cleaning</i> , <i>tokenisasi</i> , <i>stopword removal</i> , <i>stemming</i>). Melakukan uji coba <i>preprocessing</i> pada sampel teks.	Teks hasil <i>preprocessing</i> yang konsisten dan siap diekstraksi fiturnya.
Minggu 4	Ekstraksi Fitur	Membangun TF-IDF <i>vectorizer</i> untuk teks. Menerapkan one-hot <i>encoding</i> pada fitur sumber. Menyusun dua versi fitur: <i>content-only</i> dan <i>content+source</i> .	Matriks fitur final untuk skenario S1 dan S2.
Minggu 5-6	Pelatihan Model	Melatih Naïve Bayes, SVM, dan Random Forest pada kedua skenario fitur. Mencatat konfigurasi parameter model (baseline).	Enam model terlatih dari kombinasi algoritma dan skenario.
Minggu 7	Evaluasi Model	Menghitung confusion matrix, akurasi, precision, recall, dan F1-score untuk setiap model. Mengompilasi hasil evaluasi dalam tabel perbandingan performa.	Ringkasan evaluasi performa seluruh model.
Minggu 8	Penyimpanan Artefak	Menyimpan model terbaik beserta TF-IDF <i>vectorizer</i> dan <i>encoder</i> sumber. Menyimpan skrip implementasi dan <i>notebook</i> eksperimen.	Artefak penelitian lengkap dan terdokumentasi.

Melalui pembagian periode seperti pada Tabel V.1, alur implementasi menjadi le-

bih terarah dan terukur. Setiap tahap membangun fondasi bagi tahap berikutnya, sehingga proses pelatihan dan evaluasi model dapat berlangsung dengan stabil dan mengikuti *pipeline* yang telah dirancang pada Bab IV.

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

V.1.2 Alat, Lingkungan, dan Konfigurasi

Implementasi *pipeline* membutuhkan seperangkat perangkat pendukung yang memastikan proses eksperimen berjalan efisien dan *replicable*. Tabel V.2 merangkum perangkat lunak, *library*, serta konfigurasi teknis yang digunakan dalam Tugas Akhir.

Tabel V.2 Spesifikasi Alat, Bahan, dan Konfigurasi

No	Kategori	Alat/Bahan	Keterangan
1	Perangkat Keras (Hardware)	Laptop dengan CPU Intel i5/i7 atau Ryzen setara, RAM ≥ 8 GB, SSD storage	Digunakan sebagai lingkungan eksekusi utama <i>pipeline</i> ML klasik.
2	Sistem Operasi	Windows 10 / Linux Ubuntu 22.04 atau yang lebih baru	Menjadi <i>runtime environment</i> untuk Python dan library terkait.
3	Bahasa Pemrograman	Python 3.x	Bahasa utama implementasi seluruh modul <i>pipeline</i> .
4	Library Utama	scikit-learn, pandas, NumPy, Sastrawi, matplotlib	Mendukung preprocessing, TF-IDF, encoding, training model, dan evaluasi.
5	Tools Pengembangan	VS Code, Jupyter Notebook	Digunakan untuk eksplorasi, eksperimen, development, dan pencatatan hasil.

Bersambung ke halaman berikutnya

Tabel V.2 Spesifikasi Alat, Bahan, dan Konfigurasi

No	Kategori	Alat/Bahan	Keterangan
6	Manajemen Lingkungan	Anaconda / venv	Menjamin isolasi environment, kontrol dependency, dan reproduibilitas.
7	Sumber Data	Berita hoaks (TurnBackHoax), berita non-hoaks dari media kredibel	Menjadi bahan utama untuk penyusunan dataset penelitian.
8	Konfigurasi Eksperimen	Random seed konsisten, batasan vocabulary TF-IDF, encoding sumber	Menjamin stabilitas replikasi hasil dan efisiensi komputasi.
9	Biaya	Library open-source; perangkat pribadi/kampus	Tidak memerlukan biaya lisensi tambahan.

V.2 Desain Pengujian dan Evaluasi

Tahap pengujian dirancang untuk memverifikasi konsistensi implementasi *pipeline* dan mengevaluasi performa model secara kuantitatif. Metode verifikasi memastikan seluruh modul bekerja sesuai desain, sementara metode evaluasi berfokus pada perbandingan performa model di berbagai skenario fitur. Ringkasannya disajikan pada Tabel V.3.

Desain pengujian ini memberikan struktur evaluasi yang objektif dan sejalan dengan penelitian terdahulu. Dengan menggunakan dua skenario fitur, *pipeline* mampu menilai tidak hanya perbandingan antar algoritma, tetapi juga kontribusi fitur sumber terhadap peningkatan performa deteksi hoaks.

V.3 Analisis Risiko dan Mitigasi

Analisis risiko dilakukan untuk mengidentifikasi potensi hambatan yang dapat memengaruhi kelancaran Tugas Akhir, baik dari sisi data, model, maupun jadwal. Tabel V.4 menyajikan ringkasan risiko beserta langkah mitigasinya.

Tabel V.3 Tahapan Pengujian dan Evaluasi *pipeline* Deteksi Hoaks

Tahap	Deskripsi	Tujuan
Verifikasi Implementasi	Menguji modul <i>preprocessing</i> , TF-IDF, <i>encoding</i> , <i>training</i> , dan evaluasi pada subset kecil data. Menganalisis sampel jalur input-output secara manual.	Memastikan <i>pipeline</i> berjalan lancar dan sesuai desain.
Pembagian Data	<i>Train-test split</i> atau <i>k-fold cross validation</i> dengan proporsi kelas yang seimbang.	Membentuk basis evaluasi yang valid dan terkontrol.
Eksperimen per Model	Melatih NB, SVM, dan RF pada skenario S1 dan S2. Mencatat metrik kinerja dan <i>confusion matrix</i> .	Membandingkan model pada skenario fitur yang berbeda.
Evaluasi Performa	Menghitung <i>accuracy</i> , <i>precision</i> , <i>recall</i> , dan <i>F1-score</i> . Melakukan analisis <i>trade-off</i> kesalahan model.	Menilai kualitas prediksi secara komprehensif.
Penentuan Model Terbaik	Menetapkan <i>F1-score</i> sebagai metrik utama. <i>Precision</i> dan <i>recall</i> dianalisis untuk memahami risiko kesalahan.	Mengidentifikasi model yang paling efektif.
Validasi Hasil	Mengulangi eksperimen dengan <i>seed</i> berbeda atau membandingkan pola hasil dengan literatur.	Menjamin hasil stabil dan dapat dipercaya.

Tabel V.4 Identifikasi risiko dan strategi mitigasi

Jenis Risiko	Deskripsi Risiko	Mitigasi
Risiko Data	<i>Dataset</i> tidak seimbang, terdapat <i>noise</i> atau duplikasi.	Menambah variasi data, melakukan pembersihan ketat, dan menerapkan teknik <i>balancing</i> sederhana.
Risiko Model & Komputasi	Dimensi fitur besar menyebabkan pelatihan lama atau performa model rendah.	Membatasi vocabulary TF-IDF, menyederhanakan kategori sumber, serta melakukan <i>tuning</i> ringan.
Risiko Jadwal	Keterlambatan implementasi atau perubahan arahan pembimbing.	Menyusun <i>timeline</i> rinci, melakukan konsultasi rutin, dan menjaga ruang lingkup tetap fokus.
Risiko Ketidaksuaian Rencana	<i>Dataset</i> kurang atau hasil model di bawah ekspektasi.	Menyempitkan ruang lingkup Tugas Akhir atau menjadikan analisis keterbatasan sebagai kontribusi ilmiah.

DAFTAR PUSTAKA

- Alghamdi, Jawaher, Yuqing Lin, dan Suhuai Luo. 2022. "A Comparative Study of Machine Learning and Deep Learning Techniques for Fake News Detection". *Information* 13 (12). ISSN: 2078-2489. <https://doi.org/10.3390/info13120576>. <https://www.mdpi.com/2078-2489/13/12/576>.
- Alghamdi, Jawaher, Suhuai Luo, dan Yuqing Lin. 2024. "A comprehensive survey on machine learning approaches for fake news detection". *Multimedia Tools and Applications* 83 (17): 51009–51067.
- Alguttar, Abubaker A, Osama A Shaaban, dan Remzi Yildirim. 2024. "Optimized Fake News Classification: Leveraging Ensembles Learning and Parameter Tuning in Machine and Deep Learning Methods". *Applied Artificial Intelligence* 38 (1): 2385856.
- Cahyono, Hasan Dwi, Atara Mahadewa, Ardhi Wijayanto, Dewi Wisnu Wardani, dan Haryono Setiadi. 2024. "Fast Naïve Bayes classifiers for COVID-19 news in social networks". *Indonesian Journal of Electrical Engineering and Computer Science* 34 (2): 1033–1041.
- Emil, Repede Ștefan, dan Brad Remus. 2025. "A Review of Automatic Fake News Detection: From Traditional Methods to Large Language Models". *Future Internet* 17 (10): 435.
- Herdian, Cevi, Ahya Kamila, dan I Gusti Agung Musa Budidarma. 2024. "Studi Kasus Feature Engineering Untuk Data Teks: Perbandingan Label Encoding dan One-Hot Encoding Pada Metode Linear Regresi". *Technologia: Jurnal Ilmiah* 15 (1): 93–108.
- Pekandi, Louis Alexander, Reinhart Gian Widjaja, Adrian Ananta, Jeklin Harefa, dan Kenny Jingga. 2025. "Evaluating IndoBERT for Indonesian Hoax News Detection: A Comparative Study with Ensemble and CNN-LSTM Models". *Procedia Computer Science* 269:1625–1633.

- Prasetijo, Agung B., R. Rizal Isnanto, Dania Eridani, Yosua Alvin Adi Soetrisno, M. Arfan, dan Aghus Sofwan. 2017. “Hoax detection system on Indonesian news sites based on text classification using SVM and SGD”. Dalam *2017 4th International Conference on Information Technology, Computer, and Electrical Engineering (ICITACEE)*, 45–49. <https://doi.org/10.1109/ICITACEE.2017.8257673>.
- Prasetyo, Adi, Bayu Dwi Septianto, Guruh Fajar Shidik, dan Ahmad Zainul Fanani. 2019. “Evaluation of feature extraction TF-IDF in Indonesian hoax news classification”. Dalam *2019 International Seminar on Application for Technology of Information and Communication (iSemantic)*, 1–6. IEEE.
- Pratiwi, Inggrid Yanuar Risca, dan Anggit Ferdita Nugraha. 2022. “Hoax news identification using machine learning model from online media in Bahasa Indonesia”. *MATRIX: Jurnal Manajemen Teknologi dan Informatika* 12 (2): 58–67.
- Putri, Tansa TA, Irma Yanti Sitepu, Marita Sihombing, Silvi Silvi, dkk. 2019. “Analysis and detection of hoax contents in Indonesian news based on machine learning”. *Journal of Informatic Pelita Nusantara* 4 (1).
- Safira, Rachelita Embun, dan Akhsin Nurlayli. 2023. “Comparative analysis of Indonesian news validity detection accuracy using machine learning”. *Journal of Engineering and Applied Technology* 4 (1): 40–51.
- Sihombing, Pangondian. 2020. “Support Vector Machine-Based Hoax Detection on Indonesian Online News”. *International Journal of Advanced Trends in Computer Science and Engineering* 9:6202–6207. <https://doi.org/10.30534/ijatcse/2020/297942020>.
- Triyono, Liliek, Rahmat Gernowo, Mosiur Rahaman, Tri Raharjo Yudiantoro, dkk. 2023. “Indonesian Fake News Detection Using Various Machine Learning Technique”. *International Journal on Informatics Visualization* 7 (3): 726–732.